自制深度学习推理框架-第一课

> 本课程赞助方：`Datawhale`
>
> 作者：傅莘莘
>
> 特别感谢：散步，mlmz, 沉迷单车的追风少年

项目介绍

项目地址

https://github.com/zjhellofss/KuiperInfer , 欢迎大家点赞和PR.

本次课的代码地址

https://github.com/zjhellofss/kuiperdatawhale

什么是推理框架

深度学习推理框架用于对**已经训练完成的神经网络模型文件进行加载**，并根据模型文件中的**网络结构和权重参数**对输入图像进行预测。换句话说，深度学习推理框架就是将深度学习训练框架`Pytorch`和`TensorFlow`中训练完成的模型，移植到中心侧和端侧并且在运行时**高效执行**。另外，与深度学习训练框架不同的是，推理框架没有梯度后向传播的过程，因为**在推理阶段模型的权重已经固定，不需要利用后向传播技术进一步进行调整**。

例如对于一个`Resnet`分类网络的模型，深度学习推理框架先对模型文件中的网络结构进行读取和载入，再读取模型文件中的权重参数和其他参数、属性信息填入到`Resnet`网络结构中，随后推理框架**将不同的图像放入到计算图的输入**中，并**执行预测过程**，从而得到其归属的类别。以下的图示是我对如上内容的总结：

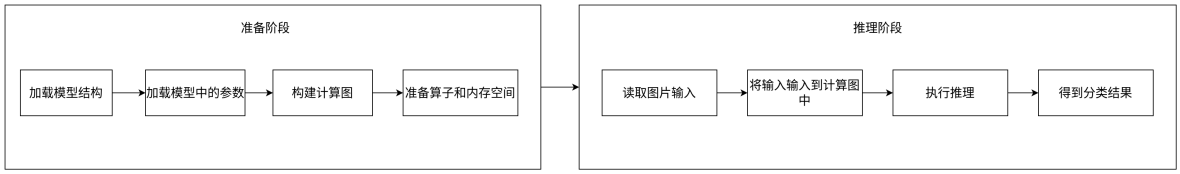

关于KuiperInfer的技术全景概述

我们在这里对本课程的成品项目`KuiperInfer`进行分模块介绍，**给同学们留一个初步的整体印象**。顺便说一句名字的来源，`Kuiper`行星带是太阳系外围的一个区域，行星带中包含着大量的冰冻小行星、彗星和其他冰质天体。之所以取这个名字，是因为我希望这个框架具有一定“边缘”属性，**另外也是希望更多的人像“小行星”一样加入到星带一样，加入到这个开源项目中。**

`KuiperInfer`可以分为以下的几个模块：

1. `Operator`:深度学习计算图中的计算节点，包含以下的几个部分：
    - **存储输入输出的张量**，用于存放深度学习中各层的输入输出。比如对于一个`Convolution`层，需要一部分空间来保存计算的输入和输出。
    - **计算节点的类型和名称**，计算节点类型可以有`Convolution`，`Relu`，`Maxpooling`等，计算节点的**名称是唯一的**，用来区分任意一个节点，可以是`Convolution_1`，`Convolution_2`等。
    - **计算节点的参数信息**，例如卷积中的步长、卷积核的大小等。
    - **计算节点的权重信息**，例如卷积节点中的`weight`，`bias`权重。
2. `Graph`: 有多个`Operator`串联得到的有向无环图，规定了各个计算节点（`Operator`）执行的流程和顺序。
3. `Layer`：计算节点中运算的具体执行者，`Layer`类先读取输入张量中的数据，然后对输入张量进行计算，得到的结果存放到计算节点的输出张量中，**当然，不同的算子中`Layer`的计算过程会不一致**。

4. `Tensor`: 用于存放**多维数据**的数据结构，方便数据在计算节点之间传递，同时该结构也封装矩阵乘、点积等与矩阵相关的基本操作。

以下的图示是对如上的模块的总结，每个节点都从输入张量`input_data`中读取数据，并调用该节点对应的`Layer`计算对应的结果，最后再将结果放入到`output_data`中。整个计算图第一个节点的输入也是计算图全局的输入，同时，最后一个节点的输出也是整个计算图的全局输出。

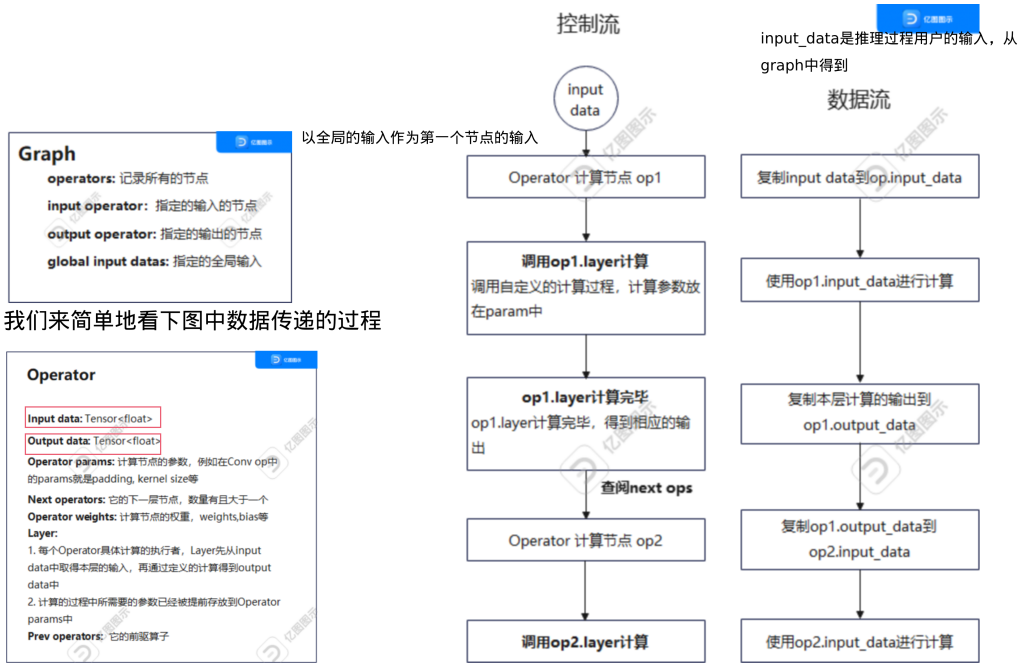

这是一个概览，同学们在目前阶段留一个印象即可，随着课程的进行我们会逐步分析其中的模块，直到掌握全局。

常见的问题

1. 对C++基础的要求是什么？如果C++水平不高怎么办？
    - 需要学过C++或者C语言，如果对自己的C++水平不够自信，可以自行阅读《C++ Primer》一书。另外在课程中，我也会穿插着去讲C++的高级语法，只要有一定基础的同学，我觉得这方面不用太担心。
2. 对AI基础的要求，会很高吗？
    - AI基础不做很高要求，但是需要知道卷积、池化、激活等基本概念，对常见模型有一定的了解，例如`Resnet`, `Yolo`, `U-net`等。
3. `KuiperInfer`和本门课程有什么关系？
    - `KuiperInfer`是本课程的上游项目，该项目的作者和本门课的作者都是同一人，而且`KuiperInfer`是**专门为了课程讲解而开发**的一个

教学性质框架，**以在设计上标准化，编码上简单化作为目标。**

- 另外在课程结束后，每位跟学跟练的同学都会具有**开发同等级推理框架的技术实力。**同时，同学们也会**逐步写出一个属于自己的深度学习AI推理框架。**在全民AI的时代，这将是一个亮点不小的个人项目，对大家以后的求职可能也会非常有帮助。

功能演示

首先要说明的是，进行功能演示的项目是我们课程结束后的成品，有基础的同学也可以自行克隆（项目地址）项目编译并调试，**但是不推荐大家现在花费过多的时间在编译项目和环境配置上。**参加的同学如果能从头到位跟听跟练课程，都能获得一个功能接近的深度学习推理框架，**具体请看视频演示。**

从零开始的环境搭建

> 根据第一次开课的经验教训，我们本次课程直接使用 `Docker` 来搭建项目的环境，请同学们跟着视频和以下步骤来一步步做。

Docker 的安装

为了同学们能够正确安装 Docker 进行环境配置，我们准备了两种操作系统下的环境安装教程，但还是更推荐同学们使用 `Linux` 环境进行课程体验。

Windows 下的 Docker 快速配置

在 Windows 下，我们可以直接安装 Docker 的桌面安装版，你可以直接进入官网下载安装包，随后一路安装。

安装完成后，我们可以直接打开 Docker-desktop，需要注意的是，如果此时报错没有开启虚拟化，你可以参考资料进行修改。

为了验证 Docker 安装成功，你可以在 `cmd` 中运行

```
docker run hello-world
```

若一切正常，你将会看到类似如下显示：

```
Unable to find image 'hello-world:latest' locally
latest: Pulling from library/hello-world
719385e32844: Pull complete
Digest:
sha256:fc6cf906cbfa013e80938cdf0bb199fbdbb86d6e3e013783e5a
766f50f5dbce0
Status: Downloaded newer image for hello-world:latest

Hello from Docker!
This message shows that your installation appears to be
working correctly.
```

Linux 下的 Docker 快速配置（推荐）

在Linux系统下，安装 Docker 也算是比较简单的操作，我们可以运行 Docker 的便捷安装脚本：

```
curl -fsSL get.docker.com -o get-docker.sh
sudo sh get-docker.sh --mirror Aliyun
```

在输入这两行命令后，Docker 即安装完毕，我们只需要启动它并赋予他权限即可：

```
sudo systemctl enable docker
sudo systemctl start docker
sudo chmod 777 /var/run/docker.sock
sudo systemctl restart docker
```

如果一切都安装完毕，你可以在终端中输入下列命令进行验证。

```
docker run hello-world
```

若一切正常，你将会看到类似如下显示：

```
Unable to find image 'hello-world:latest' locally
latest: Pulling from library/hello-world
719385e32844: Pull complete
Digest:
sha256:fc6cf906cbfa013e80938cdf0bb199fbdbb86d6e3e013783e5a
766f50f5dbce0
Status: Downloaded newer image for hello-world:latest

Hello from Docker!
This message shows that your installation appears to be
working correctly.
```

环境准备

Windows 下的环境准备

1. 拉取Docker镜像：

   ```
   docker pull registry.cn-
   hangzhou.aliyuncs.com/hellofss/kuiperinfer:datawhale
   ```

2. 创建本地文件夹，并将课程代码克隆到该文件夹中。

   ```
   git clone
   https://github.com/zjhellofss/kuiperdatawhale.git
   ```

3. 创建并运行一个镜像的容器。

   ```
   docker run -it -v 7860:22 registry.cn-
   hangzhou.aliyuncs.com/hellofss/kuiperinfer:datawhale
   /bin/bash
   ```

4. 尝试使用ssh命令连接容器，这里的**用户名固定是`me`，登录密码是1.**

   ```
   ssh -p 7860 me@127.0.0.1
   ```

Linux下的环境准备

1. 拉取Docker镜像：

```
sudo docker pull registry.cn-
hangzhou.aliyuncs.com/hellofss/kuiperinfer:datawhale
```

2. 创建本地文件夹，并将课程代码克隆到该文件夹中，这里我们用`~/code/kuipercourse`作为本地文件夹。

```
mkdir ~/code/kuiperdatawhale
cd ~/code/kuiperdatawhale
git clone
https://github.com/zjhellofss/kuiperdatawhale.git
```

3. 创建并运行一个镜像的容器。

```
sudo docker run -it registry.cn-
hangzhou.aliyuncs.com/hellofss/kuiperinfer:datawhale
/bin/bash
```

4. 在容器中输入`ifconfig`命令查看`ip`地址。（注意，这里使用的必须是172开头的地址）

```
eth0: flags=4163<UP,BROADCAST,RUNNING,MULTICAST>  mtu
1500
        inet 172.17.0.4  netmask 255.255.0.0  broadcast
172.17.255.255
        ether 02:42:ac:11:00:04  txqueuelen 0
(Ethernet)
        RX packets 55  bytes 8479 (8.4 KB)
        RX errors 0  dropped 0  overruns 0  frame 0
        TX packets 0  bytes 0 (0.0 B)
        TX errors 0  dropped 0 overruns 0  carrier 0
collisions 0
```

5. 尝试使用ssh命令连接容器，这里的**用户名固定是`me`，`ip`地址是上方`ipconfig`输出中的`inet`，登录密码是1.**

```
ssh me@172.17.0.4
```

如果出现连接超时问题，可以尝试替换映射端口或自行查阅资料解决。

6. **（可选）**`me`用户的权限或者对文件夹的读写权限，可以用`root`用户进行再次分配，`root`用户也就是在步骤3中运行容器时登录的用户。

> 至此我们已经顺利完成了环境的准备，接下来是时候选择一款心仪的IDE作为自己的开发工具，考虑到每个人喜好不同，在这里提供了VSCode 和 Clion的配置指南，你只需要选择最喜欢的即可。

用 VSCode 连接容器

1. 在 VSCode 中，连接容器是一件很简单的事情，首先你需要安装 Docker 插件，点击左侧的扩展栏（或是按下 ctrl+shift+X），键入 Docker，随后选择安装：

安装后，你将会看到左侧出现一个相同长相的小鲸鱼，左键点击它你将会看到我们启动的所有容器：

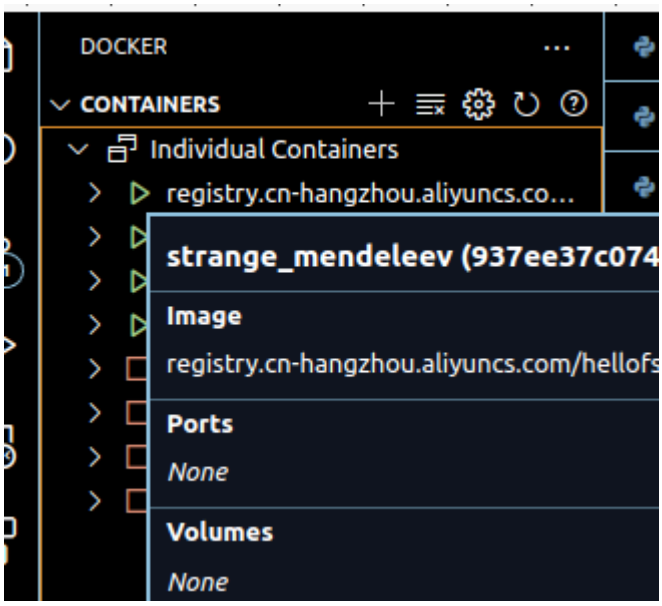

在成功进入容器之前，我们还需要再安装几个小插件，我们接着搜索 `Dev container` 以及 `Remote Development` 插件，都安装第一个即可。

2. 接下来，你需要右键之前启动的容器 `registry.cn-hangzhou.aliyuncs.com/hellofss/kuiperinfer:datawhale`，选择**附加 Visual Studio Code** 进入 Docker 环境，若你没有看到这个选项，请再次确保前面的三个插件已经都完全安装。

   在进入 Docker 环境后，我们还需要手动再次 clone 课程代码，你可以执行 `ctrl + J` 调出控制台终端，在终端中输入：

   ```
   cd /home
   git clone
   https://github.com/zjhellofss/kuiperdatawhale.git
   ```

   然后在左上角选择**文件 —— 打开文件夹 —— /home/kuiperdatawhale —— 确定**即可进入课程主界面。

3. 进入 Docker 环境后的 VSCode 拥有独立的插件环境，所以我们需要重新安装有关插件：

   你需要在此时的主界面找到扩展，且根据安装 Docker 插件的步骤自行搜索完成以下几款插件的安装：

   CMake 相关插件的安装（共三种）

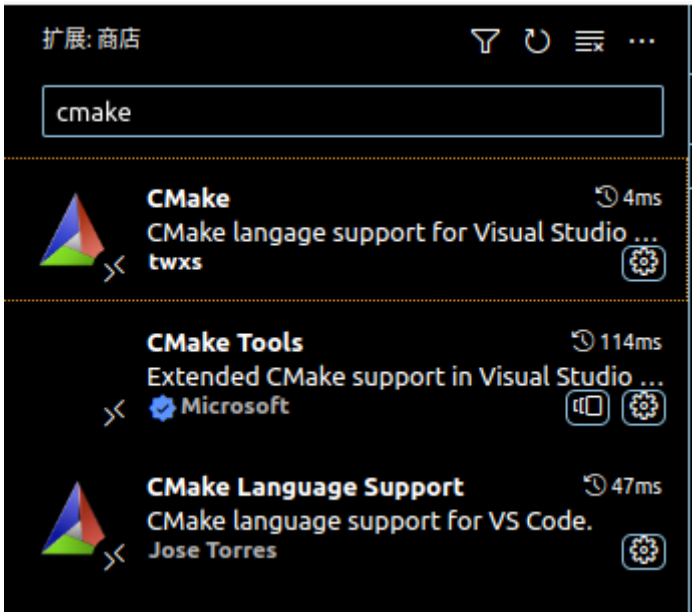

C++ 相关插件的安装（共一种）

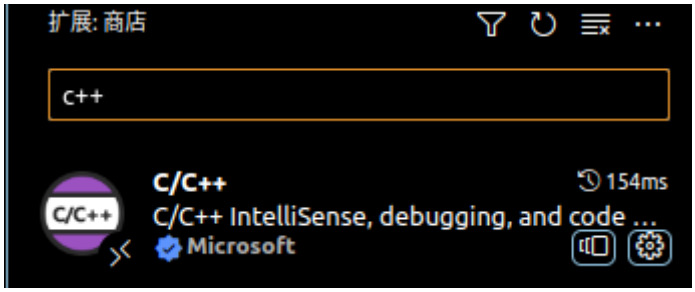

4. 在安装成功后，我们就可以开始编译调试了，你将会在下方看到如下界面：

首先，你需要点击工具图表，选择 `GCC 9.4.0 x86_64-linux-gnu` 版本的编译工具，确保编译工具一致。

接下来让我们尝试编译运行主程序，只需要在 ▶ 键右侧选择对应的编译目标（比如图中我选择了 `kuiper_datawhale_course1`），再点击 ▶ 按钮 即可开始编译运行。

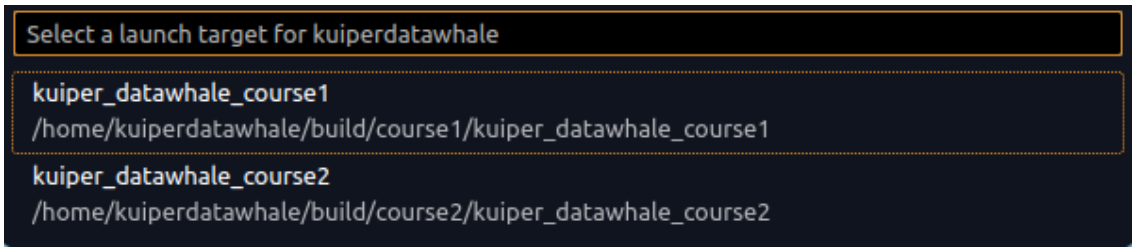

如果配置成功，程序会出现如下的运行结果，出现`Failed`这是因为本节课作业需要完成一定的代码，若作业都正确完成，`Failed`标签就会在运行结果中消失。

```
[==========] Running 7 tests from 1 test suite.
[----------] Global test environment set-up.
[----------] 7 tests from test_arma
[ RUN      ] test_arma.Axby
/tmp/tmp.dvfnZylz2q/course1/test/axby.cpp:32: Failure
Expected equality of these values:
  approx_equal(y, answer, "absdiff", 1e-5f)
    Which is: false
  true
[  FAILED  ] test_arma.Axby (0 ms)
[ RUN      ] test_arma.e_power_minus
```

除了编译程序，调试程序也是很重要的一环，在这里你可以试试看点击▶ 键旁边的小虫子键，然后观察会发生什么现象，也可以自己尝试打断点看看程序的执行流是否会停留在预期位置，甚至在调试控制台输入变量看看会出现什么结果，这里的探索就交给你。

另外，如果你想了解更多有关 VSCode 的使用方法以及调试说明，请参考资料。

用 Clion 连接容器

容器在运行的时候已经打开了一个`ssh`服务，所以我们只需要用`Clion`进行连接即可，在连接成功之后项目的代码就可以直接在容器中进行编译运行。

1. 在`Clion`的左上角点击`File-->Open`，打开项目所在的文件夹，也就是刚才的`~/code/kuiperdatawhale/kuiperdatawhale`文件夹。

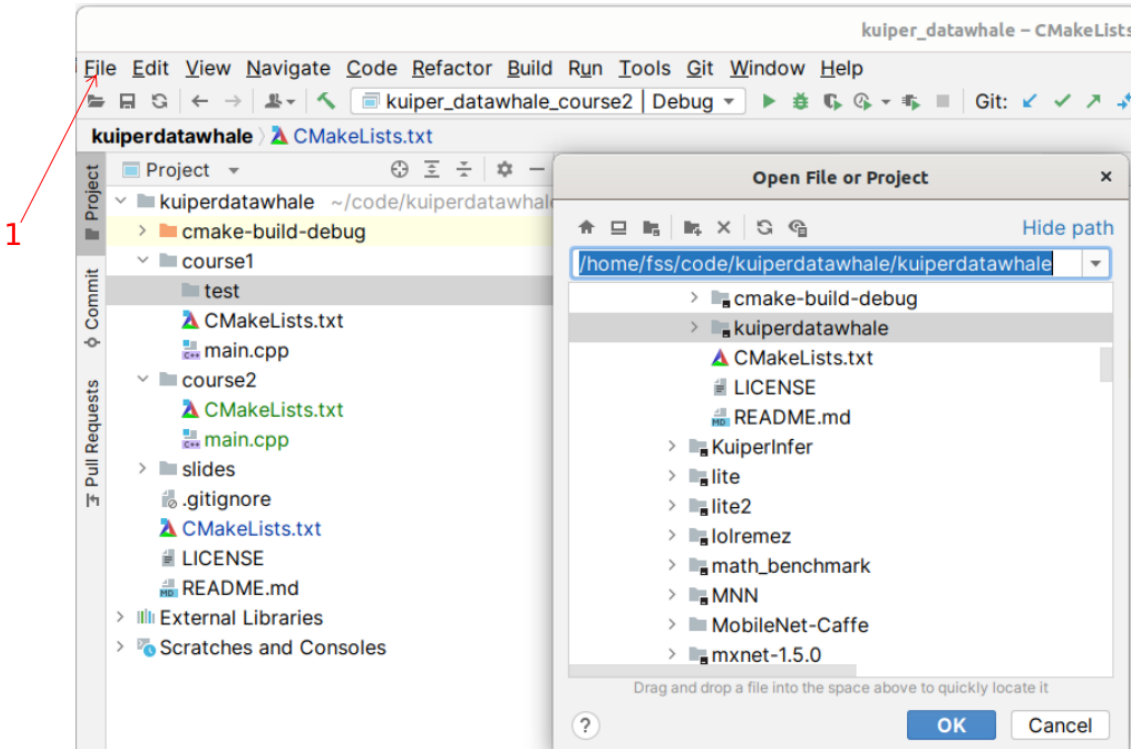

2. 在**容器内**输入`ifconfig`，注意是**容器内，不是你宿主机上**！我们可以看到`inet`对应的值为`172.17.0.4`。

   注意这里容器的`ip`地址**和你实际运行情况有关**，需要自行输入`ifconfig`命令查看，不一定是`172.17.0.4`

```
eth0: flags=4163<UP,BROADCAST,RUNNING,MULTICAST>  mtu 1500
        inet 172.17.0.4  netmask 255.255.0.0  broadcast
172.17.255.255
        ether 02:42:ac:11:00:04  txqueuelen 0  (Ethernet)
        RX packets 55  bytes 8479 (8.4 KB)
        RX errors 0  dropped 0  overruns 0  frame 0
        TX packets 0  bytes 0 (0.0 B)
        TX errors 0  dropped 0 overruns 0  carrier 0
collisions 0
```

3. 在确保容器已经在运行后，再在`Clion`的`Toolchain`设置为容器内的编程环境
   - 点击`Clion`软件左上角的`File->Settings`，并在左侧对应位置找到`Toolchains`

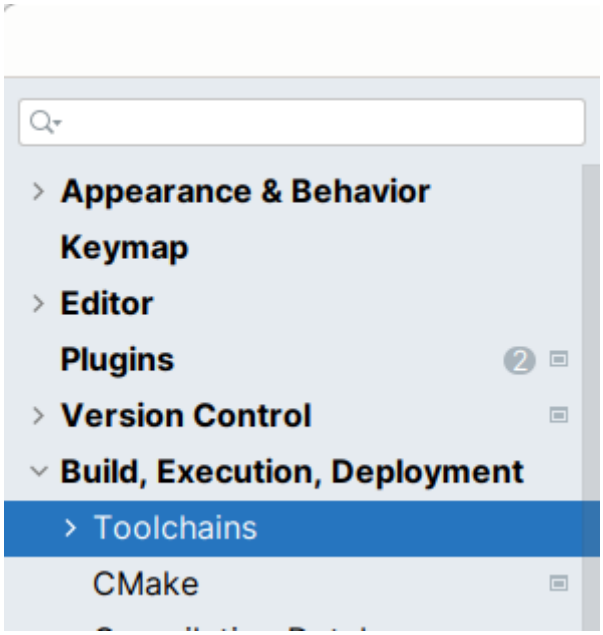

- 请按图示的顺序进行操作，在3处将host修改为容器中输入`ifconfig`命令得到的`ip`地址，**并将`username`设置为`me`，登录方式为密码登录，密码为1**.
- 所有信息填好之后点击`Test Connection`. 如果连接成功，则会显示`Connected Successfully`，如果此处连接失败，可以尝试替换映射端口或自行查阅资料解决。

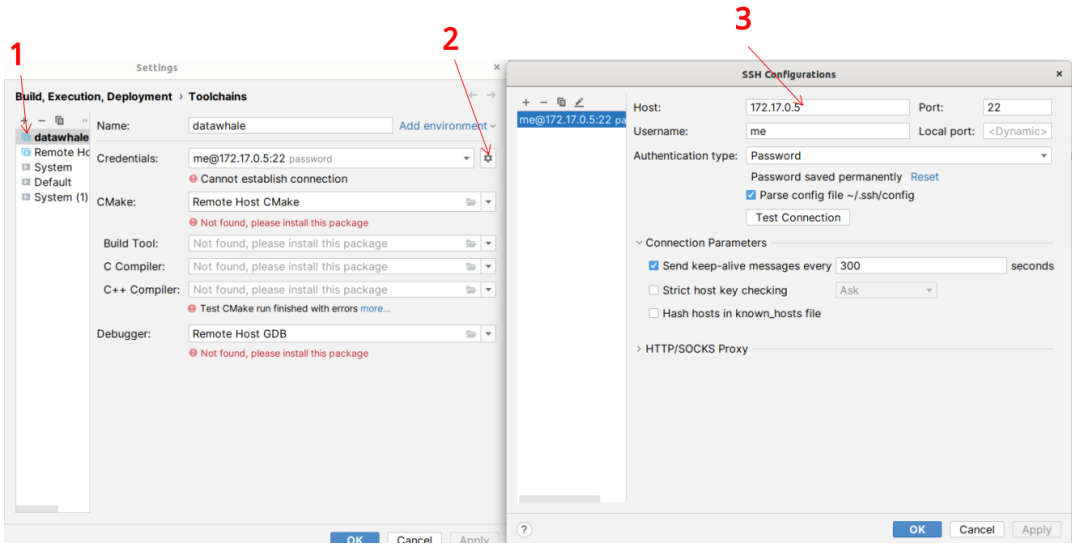

- 随后将`datawhale`一栏拖动到最上方（鼠标左键拖动），表示**软件默认使用容器内的编译工具链**。

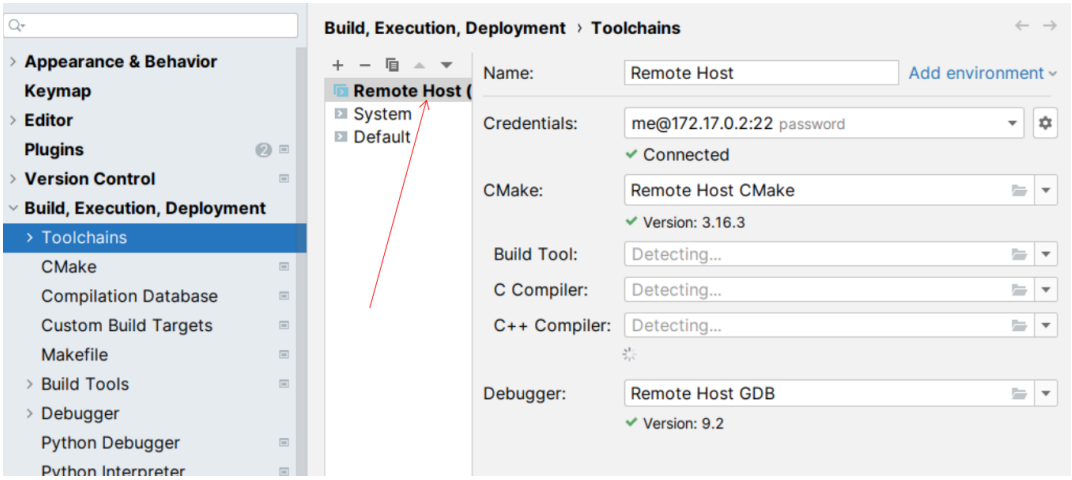

4. 现在编程环境已经配置到了`Docker`容器中，随后点击菜单栏的`Helps->Find actions`，再输入`Reload Cmake Project`对项目进行重新加载，包括如果你之后修改了`Cmake`文件，最好都用这个命令重新加载下项目。
    - **如果发现头文件报错或者不能智能提示**，可以在`Find actions`中输入`resync with remote hosts`来同步远程的头文件。

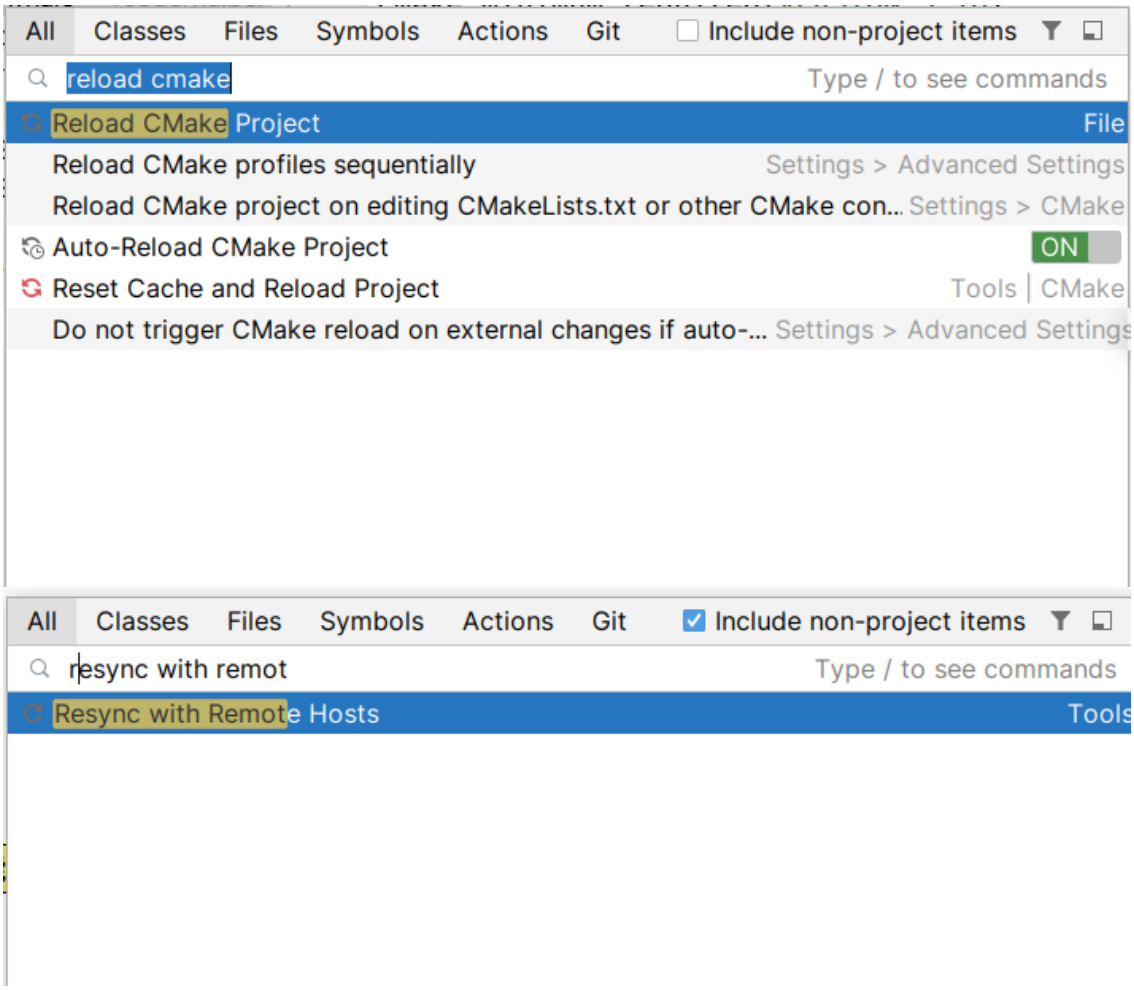

5. 随后就可以选择`course1`并点击三角形按钮对项目代码进行执行。

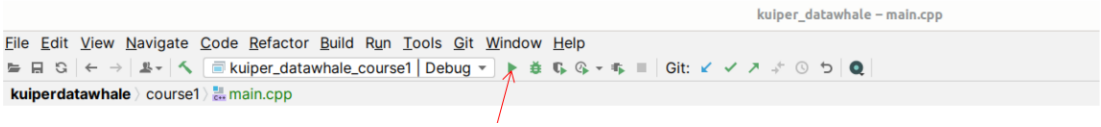

如果配置成功，程序会出现如下的运行结果，出现`Failed`这是因为本节课作业需要完成一定的代码，若作业都正确完成，`Failed`标签就会在运行结果中消失。

```
[==========] Running 7 tests from 1 test suite.
[----------] Global test environment set-up.
[----------] 7 tests from test_arma
[ RUN      ] test_arma.Axby
/tmp/tmp.dvfnZylz2q/course1/test/axby.cpp:32: Failure
Expected equality of these values:
  approx_equal(y, answer, "absdiff", 1e-5f)
    Which is: false
  true
[  FAILED  ] test_arma.Axby (0 ms)
[ RUN      ] test_arma.e_power_minus
```

如果对以上配置远程开发的过程还有疑问，可以参考资料.

如何写单元测试

搭建好了环境，我们来写一些单元测试看看运行情况。同时，在这个过程中，我们也试着去写项目的单元测试。单元测试框架使用了`Google`的`Google Test`，该框架已经在`Docker`镜像中提供。 我们以矩阵库`armadillo`的计算接口作为我们的测试目标，在测试的过程中也去熟悉这个矩阵库的基本用法，以下是`armadillo`矩阵库的文档地址，以供我们在学习的过程中查阅：armadillo documentation.

在`test/test1.cpp`中有以下的几个函数：

1. `test_add`函数用来测试`armadillo`的矩阵加法接口

```
TEST(test_arma, add) {
  using namespace arma;
  fmat in_matrix1 = "1,2,3;"
                    "4,5,6;"
                    "7,8,9";

  fmat in_matrix2 = "1,2,3;"
                    "4,5,6;"
```

```
                    "7,8,9";

  const fmat &out_matrix1 = "2,4,6;"
                            "8,10,12;"
                            "14,16,18";

  const fmat &out_matrix2 = in_matrix1 + in_matrix2;
  ASSERT_EQ(approx_equal(out_matrix1, out_matrix2,
"absdiff", 1e-5), true);
}
```

2. `test_sub`函数用来测试`armadillo`的矩阵减法接口

```
TEST(test_arma, sub) {
  using namespace arma;
  fmat in_matrix1 = "1,2,3;"
                    "4,5,6;"
                    "7,8,9";

  fmat in_matrix2 = "1,2,3;"
                    "4,5,6;"
                    "7,8,9";

  const fmat &out_matrix1 = "0,0,0;"
                            "0,0,0;"
                            "0,0,0;";

  const fmat &out_matrix2 = in_matrix1 - in_matrix2;
  ASSERT_EQ(approx_equal(out_matrix1, out_matrix2,
"absdiff", 1e-5), true);
}
```

3. `test_matmul`用来测试`armadillo`的矩阵乘法接口

```
TEST(test_arma, matmul) {
  using namespace arma;
  fmat in_matrix1 = "1,2,3;"
                    "4,5,6;"
                    "7,8,9";
```

```
  fmat in_matrix2 = "1,2,3;"
                    "4,5,6;"
                    "7,8,9";

  const fmat &out_matrix1 = "30,36,42;"
                            "66,81,96;"
                            "102,126,150;";

  const fmat &out_matrix2 = in_matrix1 * in_matrix2;
  ASSERT_EQ(approx_equal(out_matrix1, out_matrix2,
"absdiff", 1e-5), true);
}
```

4. `test_pointwise`用来测试`armadillo`的矩阵点积接口

```
TEST(test_arma, pointwise) {
  using namespace arma;
  fmat in_matrix1 = "1,2,3;"
                    "4,5,6;"
                    "7,8,9";

  fmat in_matrix2 = "1,2,3;"
                    "4,5,6;"
                    "7,8,9";

  const fmat &out_matrix1 = "1,4,9;"
                            "16,25,36;"
                            "49,64,81;";

  const fmat &out_matrix2 = in_matrix1 % in_matrix2;
  ASSERT_EQ(approx_equal(out_matrix1, out_matrix2,
"absdiff", 1e-5), true);
}
```

我们将所有的测试代码都放在了`test`文件夹下，`Cmake`构建系统会去自动读取该文件夹下的单元测试文件，**如果新添加了`.cpp`文件或者新的单元测试函数**，需要使用`Reload Cmake Project`重新进行载入。

本节作业

1. 在`axby.cpp`中编写$Y = w \times x + b$的代码，其中w和b是一个向量，并通过其中的单元测试，请自行查阅资料。
2. 在`axby.cpp`中编写$Y = e^{-x}$的代码，并通过其中的单元测试，请自行查阅资料。
3. 在`axby.cpp`中编写$Y = a \times x + y$的代码，其中a和y是一个标量，同样需要通过单元测试，请自行查阅资料。