


自制深度学习推理框架-第一课

本课程赞助方：`Datawhale`

作者：傅莘莘



Datawhale

项目介绍

项目地址

<https://github.com/zjhelloworld/KuiperInfer>，欢迎大家点赞和PR.


本次课的代码地址

Todo

什么是推理框架

深度学习推理框架用于对**已经训练完成的神经网络模型文件进行加载**，并根据模型文件中的**网络结构和权重参数**对输入图像进行预测。换句话说，深度学习推理框架就是将深度学习训练框架 `Pytorch` 和 `TensorFlow` 中训练完成的模型，移植到中心侧和端侧并且**高效执行**。另外，与深度学习训练框架不同的是推理框架没有梯度后向传播的过程，因为在**推理阶段模型的权重已经固定，不需要利用后向传播技术进一步进行调整**。

例如对于一个 `Resnet` 分类网络的模型，深度学习推理框架先对模型文件中的网络结构进行读取和载入，再读取模型文件中的权重参数和其他参数、属性信息填入到 `Resnet` 网络结构中，随后推理框架**将不同的图像放入到计算图的输入中，并执行预测过程**，从而得到其归属的类别。以下的图示是我对如上内容的总结：



关于KuiperInfer的技术全景概述

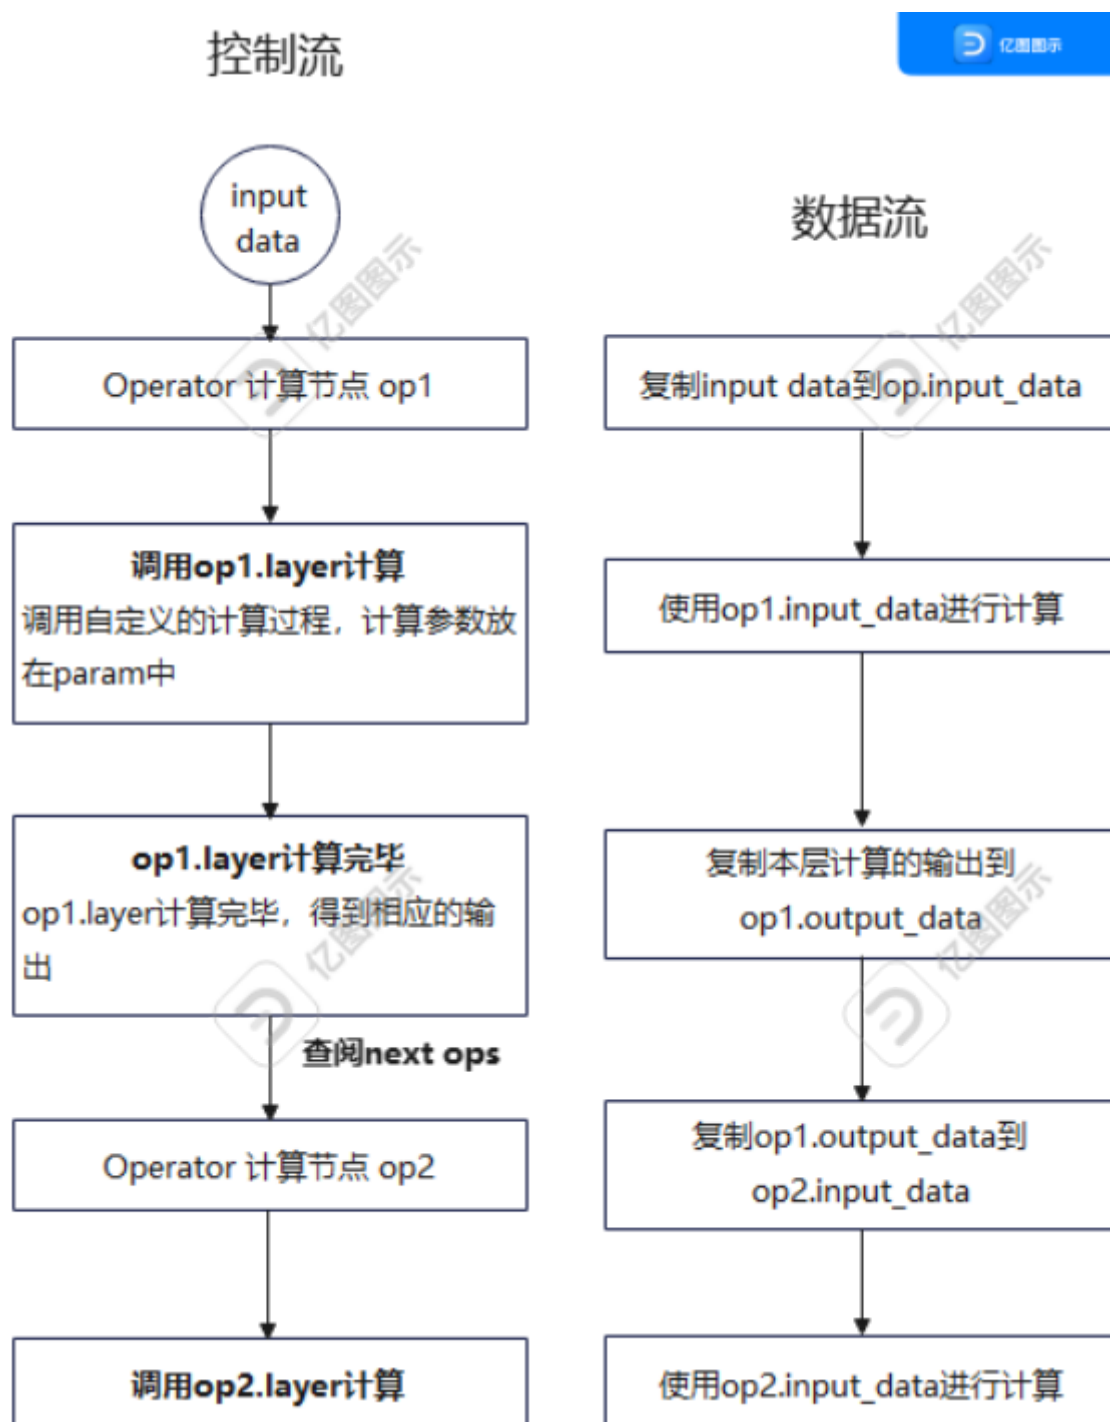
我们在这里对本课程的成品项目 **KuiperInfer** 进行分模块介绍，**给同学们留一个初步的整体印象**。顺便说一句名字的来源，**Kuiper** 行星带是太阳系外围的一个区域，行星带中包含着大量的冰冻小行星、彗星和其他冰质天体。之所以取这个名字，是因为我希望这个框架具有一定“边缘”属性，另外也是希望更多的人像“小行星”一样加入到星带一样，加入到这个开源项目中，以下是项目的 **Logo**：



KuiperInfer 可以分为以下的几个模块：

1. **Operator**: 深度学习计算图中的计算节点，包含以下的几个部分：
 - **输入输出的张量**，用于存放深度学习中各层的输入输出。比如对于一个 **Convolution** 层，需要一部分空间来保存计算的输入和输出。
 - **计算节点的类型和名称**，计算节点类型可以有 **Convolution**, **Relu**, **Maxpooling** 等，计算节点的名称是唯一的，用来区分任意一个节点，可以是 **Convolution_1**, **Convolution_2** 等。
 - **计算节点参数信息**，例如卷积中的步长、卷积核的大小等。
 - **计算节点的权重信息**，例如卷积节点中的 **weight**, **bias** 权重。
2. **Graph**: 有多个 **Operator** 串联得到的有向无环图，规定了各个计算节点（**Operator**）执行的流程和顺序。
3. **Layer**: 计算节点中运算的具体执行者，**Layer** 类先读取输入的张量，然后对输入张量进行计算，得到的结果存放到计算节点的输出张量中。
4. **Tensor**: 用于存放多维数据的数据结构，方便数据在计算节点之间传递。

以下的图示是对如上的模块的总结，每个节点都从输入张量中读取数据，并调用该节点对应的 `Layer` 计算结果，最后再将结果放入到 `output_data` 中。



常见的问题

1. 对C++基础的要求是什么？如果C++水平不高怎么办？
 - 需要学过C++或者C语言，如果对自己的C++水平不够自信，可以自行阅读《C++ Primer》一书。另外在课程中，我也会穿插着去讲C++的高级语法，只要有一定基础的同学，我觉得这方面不用太担心。

2. 对AI基础的要求，会很高吗？

- AI基础不做很高要求，但是需要知道卷积、池化、激活等基本概念，对常见模型有一定的了解，例如 `Resnet`, `Yolo`, `U-net` 等。

3. KuiperInfer和本门课程有什么关系？

- KuiperInfer是本课程的上游项目，该项目的作者和本门课的作者都是同一人，而且KuiperInfer是**专门为了课程讲解而开发**的一个教学性质框架，**在设计和编码上都以简单化作为目标**。
- 另外在课程结束后，每位跟学跟练的同学都会具有**开发同等级推理框架的技术实力**。同时，同学们也会**逐步写出一个属于自己的深度学习AI推理框架**。在全民AI的时代，这将是一个亮点不小的个人项目，对大家以后的求职可能也会非常有帮助。

功能演示

首先要说明的是，进行功能演示的项目是我们课程结束后的成品，有基础的同学也可以自行克隆（[项目地址](#)）项目编译并调试。参加的同学如果能从头到位跟听跟练课程，都能获得一个功能接近的深度学习推理框架，具体请看视频演示。

从零开始的环境搭建

根据第一次开课的经验教训，我们本次课程直接使用 `Docker` 来搭建项目的环境，请同学们跟着视频和以下步骤来一步步做。

环境准备

1. 拉取Docker镜像：

```
sudo docker pull registry.cn-  
hangzhou.aliyuncs.com/hellofss/kuiperinfer:datawhale
```

2. 创建本地文件夹，并将课程代码克隆**Todo(datawhale提供的仓库)**到该文件夹中，这里我们用 `~/code/kuipercourse` 作为本地文件夹。

```
mkdir ~/code/kuiperdatawhale
cd ~/code/kuiperdatawhale
git clone
https://github.com/zjhellofss/kuiperdatawhale.git
```

3. 创建并运行一个镜像的容器。

```
sudo docker run -it registry.cn-
hangzhou.aliyuncs.com/hellofss/kuiperinfer:datawhale
/bin/bash
```

4. 在容器中输入 `ifconfig` 命令查看 ip 地址。

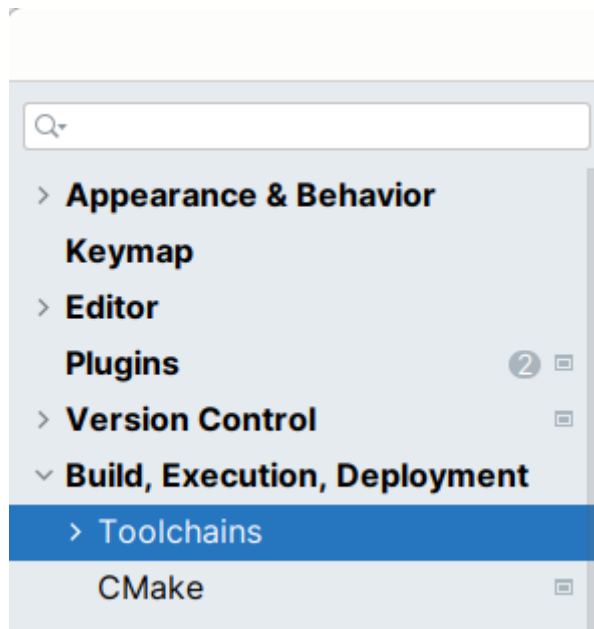
用Clion连接容器

容器在运行的时候已经打开了一个 `ssh` 服务，所以我们只需要用 `Clion` 进行连接即可。

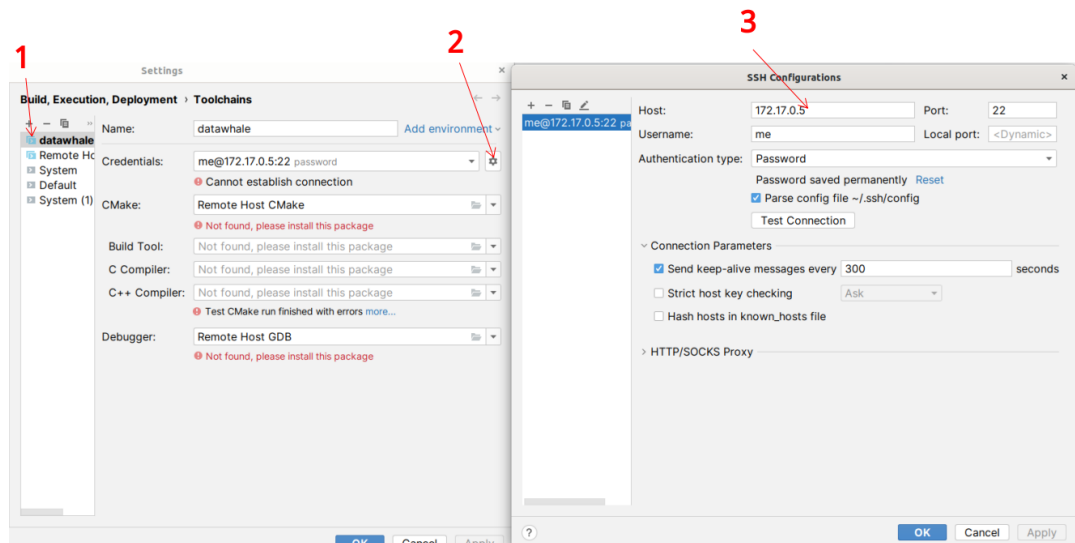
1. 在 `Clion` 的左上角点击 `File-->Open`，打开项目所在的文件夹，也就是刚才的 `~/code/kuiperdatawhale/kuiperdatawhale` 文件夹。
2. 在**容器内**输入 `ifconfig`，注意是**容器内**，**不是你宿主机上**！我们可以看到 `inet` 对应的值为 `172.17.0.4`。注意这里容器的 `ip` 地址和你**实际运行情况有关**，需要自行输入 `ifconfig` 命令查看，不一定是 `172.17.0.4`

```
eth0: flags=4163<UP,BROADCAST,RUNNING,MULTICAST> mtu 1500
    inet 172.17.0.4 netmask 255.255.0.0 broadcast
172.17.255.255
    ether 02:42:ac:11:00:04 txqueuelen 0 (Ethernet)
    RX packets 55 bytes 8479 (8.4 KB)
    RX errors 0 dropped 0 overruns 0 frame 0
    TX packets 0 bytes 0 (0.0 B)
    TX errors 0 dropped 0 overruns 0 carrier 0
collisions 0
```

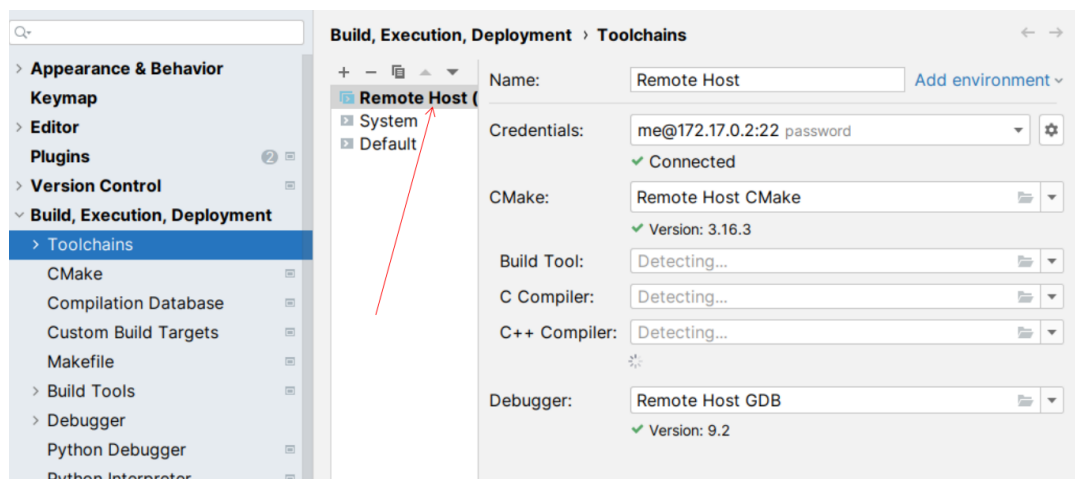
3. 在确保容器已经在运行后，再在 `Clion` 的 `Toolchain` 设置为容器内的编程环境
 - 点击 `Clion` 软件左上角的 `File->Settings`，在左侧对应位置找到 `Toolchains`



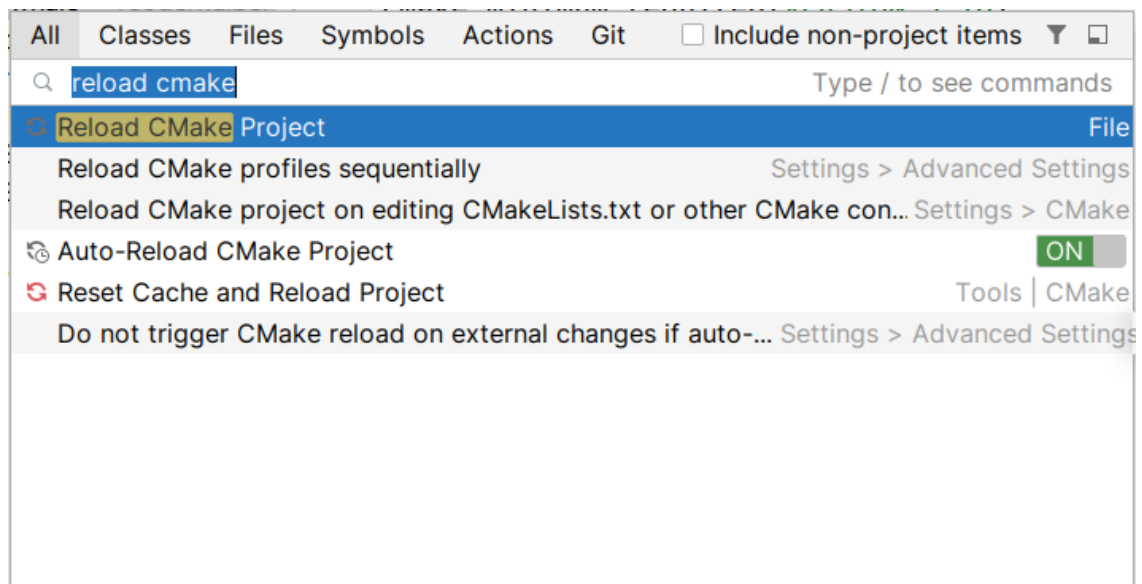
- 请按图示的顺序进行操作，在3处将host修改为容器中输入 `ifconfig` 命令得到的 ip 地址，并将 username 设置为 `me`，登录方式为密码登录（password），密码为1。所有信息填好之后点击 `Test Connection`。如果连接成功，则会显示 `Connected Successfully`



- 随后将 `datawhale` 一栏拖动到最上方（鼠标左键拖动），表示软件默认使用容器内的编译工具链。



4. 现在编程环境已经配置到了 Docker 容器中，随后点击菜单栏的 Help->Find actions, 再输入 Reload Cmake Project 对项目进行重新加载。



5. 随后就可以点击三角形按钮对项目代码进行执行。

如果对以上配置远程开发的过程还有疑问，可以参考[资料](#)。

一些基础的C++知识

如何写单元测试

搭建好了环境，我们来写一些单元测试看看运行情况。同时，在这个过程中，我们也试着去写项目的单元测试。单元测试框架使用了 Google 的 Google Test, 该框架已经在 Docker 镜像中提供。

我们以矩阵库 `armadillo` 的计算接口作为我们的测试目标，在测试的过程中也去熟悉这个矩阵库的基本用法。以下是文档地址，以供我们在学习的过程中查阅：[armadillo documentation](http://arma.sourceforge.net/docs.html).

我们将所有的测试代码都放在了 `test` 文件夹下，`Cmake` 构建系统会自动读取该文件夹下的单元测试文件，如果新添加了 `.cpp` 文件，需要使用 `Reload Cmake Project` 重新进行载入。文件夹中有以下的几个测试文件，分别用来测试 `armadillo` 矩阵库的加减和矩阵乘法接口。

本节作业
