第六课-卷积和池化算子的实现

> 本课程赞助方：`Datawhale`
>
> 作者：傅莘莘，陈焕
>
> 主项目：https://github.com/zjhellofss/KuiperInfer 欢迎大家点赞和PR.
>
> 课程代码：https://github.com/zjhellofss/kuiperdatawhale/course4

上节课程回顾

在上一节课中，我带大家实现了算子的注册工厂和实例化，并且教大家如何实现了第一个简单的算子`ReLU`. 在上节课的基础上，本节课我将继续带着大家实现两个常见的算子——池化算子和卷积算子，它们在卷积网络中非常常见。

池化算子的定义

池化算子常用于缓解深度神经网络对位置的过度敏感性。

池化算子会在固定形状的窗口（即池化窗口）内对输入数据的元素进行计算，计算结果可以是池化窗口内元素的最大值或平均值，这种运算被称为最大池化或平均池化。

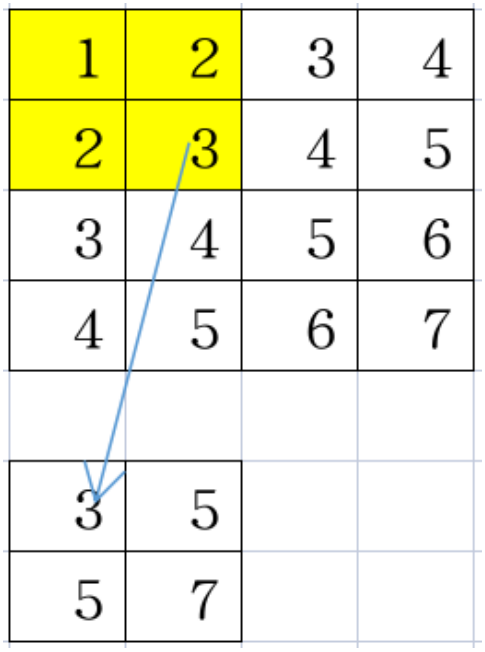

以上图为例，黄色区域表示一个2 x 2的池化窗口。在二维最大池化中，池化窗口从输入张量的左上角开始，按照从左往右、从上往下的顺序依次滑动（滑动的幅度称为`stride`）。在每个池化窗口内，取窗口中的最大值或平均值作为输出张量相应位置的元素。

本例中采用最大池化，即每次都取窗口中的最大值，滑动的`stride`等于2。当时刻t等于2或3时，池化窗口的位置如下所示：

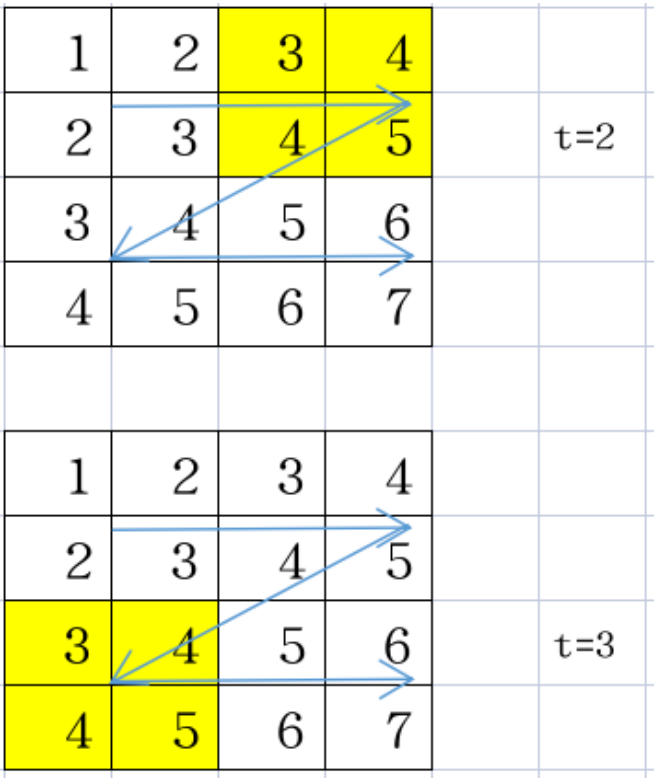

当t等于2时，池化窗口的输出为5, 也就是窗口内最大的元素为5. 当t等于3时，池化窗口向左下移动，池化窗口的输出同样是5. 所以，该输入特征图的最大池化计算结果输出如下，不难看出，输出中的每个位置都对应于原始输入窗口中的最大值。

3	5
5	7

每次进行池化操作时，池化窗口都按照从左到右、从上到下的顺序进行滑动。窗口每次向下移动的步长为`stride height`，向右移动的步长为`stride width`. 池化操作的元素数量由`pooling height`和`pooling width`所组成的池化窗口决定。

根据图示，可知在本例中`stride width`的值为2，即窗口每次向右移动的距离为2个元素大小。我们在下图中展示了一个`stride = 1`的情况，即池化窗口每次滑动一个元素的位置。这意味着在进行池化操作时，池化窗口每次向下移动和向右移动的步长均为1个元素的大小，请参考下图以获得更直观的理解。

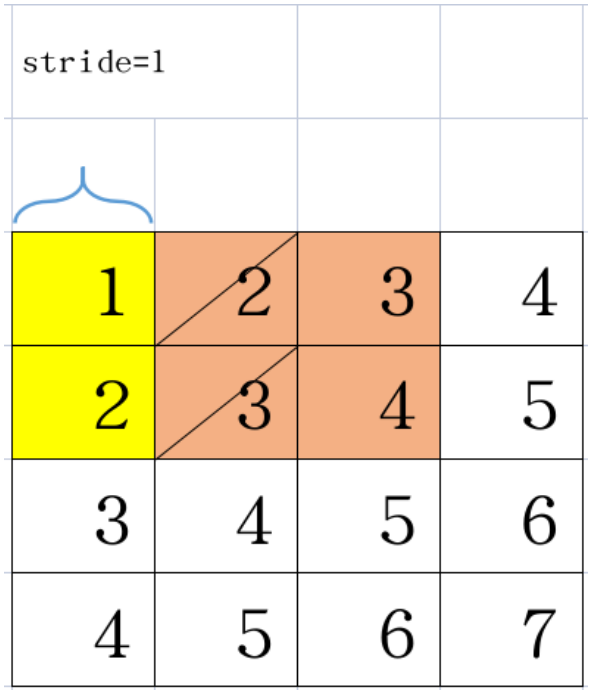

1	2	3	4
2	3	4	5
3	4	5	6
4	5	6	7

对于不带填充的池化算子，输入大小和输出大小之间有如下的等式关系：

$$output\ size = floor(\frac{input - pooling\ size}{stride} + 1)$$

对填充后的输入特征图求池化

在池化算子中，通常会先对输入特征进行填充(`padding`)，当`padding`的值等于2时，池化算子会先在输入特征的周围填充**2圈最小值元素**，然后再计算其对应的池化值。

		1	2	3	4		
		2	3	4	5		
		3	4	5	6		
		4	5	6	7		

-inf	-inf	-inf	-inf	-inf	-inf	-inf	-inf
-inf	-inf	-inf	-inf	-inf	-inf	-inf	-inf
-inf	-inf	1	2	3	4	-inf	-inf
-inf	-inf	2	3	4	5	-inf	-inf
-inf	-inf	3	4	5	6	-inf	-inf
-inf	-inf	4	5	6	7	-inf	-inf
-inf	-inf	-inf	-inf	-inf	-inf	-inf	-inf
-inf	-inf	-inf	-inf	-inf	-inf	-inf	-inf

对于带填充的池化算子，输出特征图的大小和输入特征图的大小之间有以下等式关系：

$$output\ size = floor(\frac{input\ size + 2 \times padding - pooling\ size}{stride} + 1)$$

多通道的池化算子定义

多通道的池化算子和单通道上的池化算子实现方式基本相同，只不过多通道池化需要对输入特征中的多个通道进行池化运算。

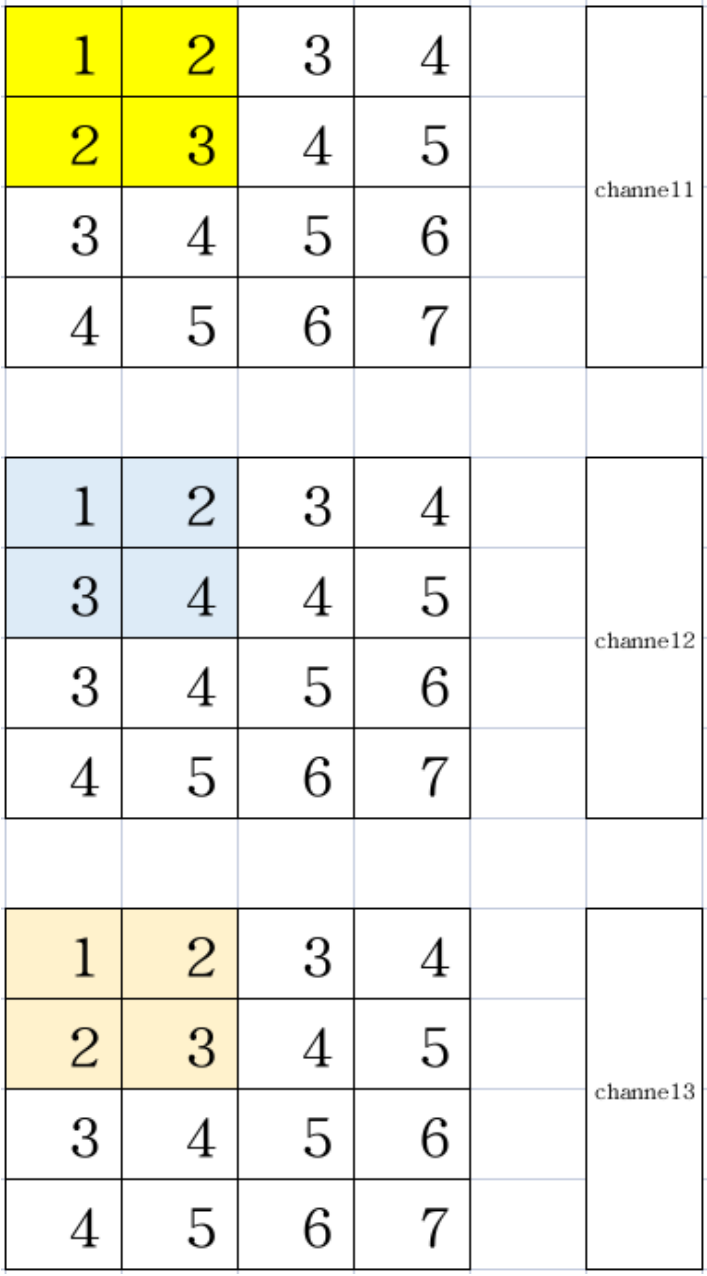

我们对通道数量为3的输入特征图进行最大池化操作时，使用滑动步长(`stride`)为1和窗口大小为2. 下图以第3个通道为例进行说明。

max=3	1	2	3	4		
	2	3	4	5		t=1
	3	4	5	6		
	4	5	6	7		
max=4	1	2	3	4		
	2	3	4	5		t=2
	3	4	5	6		
	4	5	6	7		
max=5	1	2	3	4		
	2	3	4	5		t=3
	3	4	5	6		
	4	5	6	7		
max=4	1	2	3	4		
	2	3	4	5		t=3
	3	4	5	6		
	4	5	6	7		

在进行池化操作时，在不同的时刻，每次池化窗口的移动大小均为1。同时，窗口滑动需要按照先**左后右、先上后下的顺序**遍历完整个输入通道。这保证了在求取最大池化值时，覆盖到所有可能的位置，并确保结果的准确性，同样的方式也适用于处理其他两个通道的数据。

最大池化算子的实现

> 最大池化指的是在一个窗口的范围内，取所有元素的最大值

最大池化算子的源代码位于`course6`文件夹下的`maxpooling.cpp`文件中，我们会逐一对其实现进行讲解。

在上节课中，**我们讲到所有算子都会派生于`Layer`父类并重写其中带参数的`Forward`方法，子类的`Forward`方法会包含派生类算子的具体计算过程**，一般包括以下几个步骤

1. 逐一从输入数组中提取输入张量，并对其进行空值和维度检查；
2. 根据算子的定义和输入张量的值，执行该算子的计算；
3. 将计算得到的结果写回到输出张量中。

```
1  InferStatus MaxPoolingLayer::Forward(
2      const
   std::vector<std::shared_ptr<Tensor<float>>>& inputs,
3      std::vector<std::shared_ptr<Tensor<float>>>&
   outputs) {
4    if (inputs.empty()) {
5      LOG(ERROR) << "The input tensor array in the max
   pooling layer is empty";
6      return InferStatus::kInferFailedInputEmpty;
7    }
8
9    if (inputs.size() != outputs.size()) {
10     LOG(ERROR)
11         << "The input and output tensor array size
   of the max pooling layer "
12            "do not match";
13     return
   InferStatus::kInferFailedInputOutSizeMatchError;
14   }
```

在以上的代码的第4行中，判断输入的张量数组是否为空，如果为空则返回对应的错误码。同样在第9行中，如果发现输入和输出的张量个数不相等，也返回相应的错误码。值得说明的是，我们将输入和输出的张量个数记作`batch size`，也就是一个批次处理的数据数量。

```
1  for (uint32_t i = 0; i < batch; ++i) {
```

```
2       const std::shared_ptr<Tensor<float>>& input_data
    = inputs.at(i);
3       ...
4       ...
5       const uint32_t input_h = input_data->rows();
6       const uint32_t input_w = input_data->cols();
7       const uint32_t input_padded_h = input_data-
    >rows() + 2 * padding_h_;
8       const uint32_t input_padded_w = input_data-
    >cols() + 2 * padding_w_;
9
10      const uint32_t input_c = input_data->channels();
11
12      const uint32_t output_h = uint32_t(
13          std::floor((int(input_padded_h) -
    int(pooling_h)) / stride_h_ + 1));
14      const uint32_t output_w = uint32_t(
15          std::floor((int(input_padded_w) -
    int(pooling_w)) / stride_w_ + 1));
16
```

在以上的代码中，我们对`batch size`个输入张量进行遍历处理。在第5 - 6行的代码中，我们获得该输入张量的高度和宽度，并在12 - 15行代码中，我们根据以下的公式对池化的输出大小进行计算。

$$output\ size = floor(\frac{input\ size + 2 \times padding - pooling\ size}{stride} + 1)$$

```
1 for (uint32_t ic = 0; ic < input_c; ++ic) {
2     const arma::fmat& input_channel = input_data->slice(ic);
3     arma::fmat& output_channel = output_data->slice(ic);
4     for (uint32_t c = 0; c < input_padded_w - pooling_w + 1; c += stride_w_) {
5         for (uint32_t r = 0; r < input_padded_h - pooling_h + 1;
6              r += stride_h_) {
7             循环中的内容
8         }
9     }
```

第1行是对多通道的输入特征图进行逐通道的处理，每次进行一个通道上的最大池化操作，首先获取当前输入张量上的第`ic`个通道`input_channel`.

在第4-5行的代码中，我们在输入特征图中进行窗口移动（就如同我们上面的图示一样），每次纵向移动的步长为`stride_h`,每次横向移动的步长为`stride_w`.

```
1  float* output_channel_ptr = output_channel.colptr(int(c / stride_w_));
2  float max_value = std::numeric_limits<float>::lowest();
3  for (uint32_t w = 0; w < pooling_w; ++w) {
4      for (uint32_t h = 0; h < pooling_h; ++h) {
5          float current_value = 0.f;
6          if ((h + r >= padding_h_ && w + c >= padding_w_) &&
7              (h + r < input_h + padding_h_ &&
8               w + c < input_w + padding_w_)) {
9              const float* col_ptr = input_channel.colptr(c + w - padding_w_);
10             current_value = *(col_ptr + r + h - padding_h_);
```

```
11          } else {
12              current_value =
    std::numeric_limits<float>::lowest();
13          }
14          max_value = max_value > current_value ?
    max_value : current_value;
15      }
16  }
17  *(output_channel_ptr + int(r / stride_h_)) =
    max_value;
```

在第3 - 4行的内部循环中，我们对一个窗口内的`pooling_h` × `pooling_w`个元素求得最大值。在这个内部循环中，有两种情况（使用`if`判断的地方）：

- 第一种情况(第6行)是当前遍历的元素位于有效范围内，我们将该元素的值记录下来；
- 第二种情况(第12行)是当前遍历的元素超出了输入特征图的范围，在这种情况下，我们将该元素的值赋值为一个最小值。

以下是关于无效值范围的图示。我们可以观察到，在一个窗口大小为3的池化算子中，**当该窗口移动到特定位置时，就会出现无效范围，即超出了输入特征图的尺寸限制**。

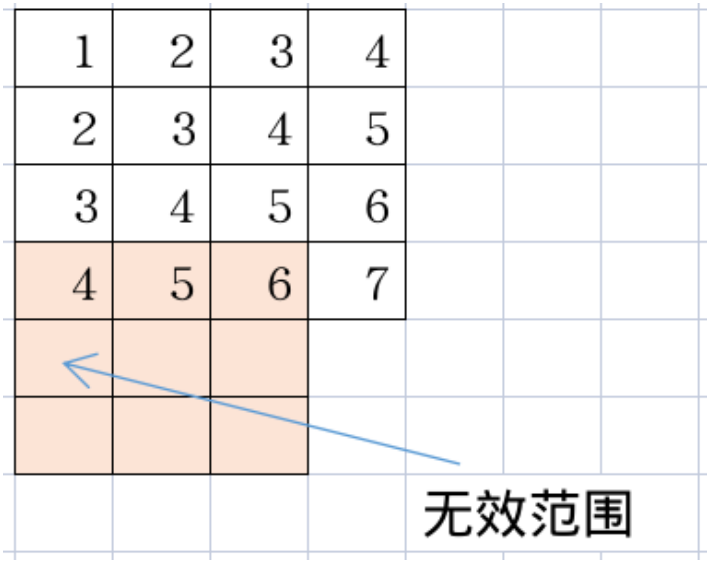

在内部循环中，当获取到窗口的最大值后，我们需要将该最大值写入到对应的输出张量中。以下是输出张量写入的位置索引：

1. `output_data->slice(ic);` 获得第`ic`个输出张量；
2. `output_channel.colptr(int(c / stride_w_));` 计算第`ic`个张量的**输出列位置**，列的值和当前窗口的位置有关，`c`表示滑动窗口当前所在的列数.
3. `*(output_channel_ptr + int(r / stride_h_)) = max_value;` 计算输出的行位置，行的位置同样与当前窗口的滑动有关，`h`表示当前滑动窗口所在的行数。

我们以下面的图示作为一个例子来讲解对`output`的输出位置：

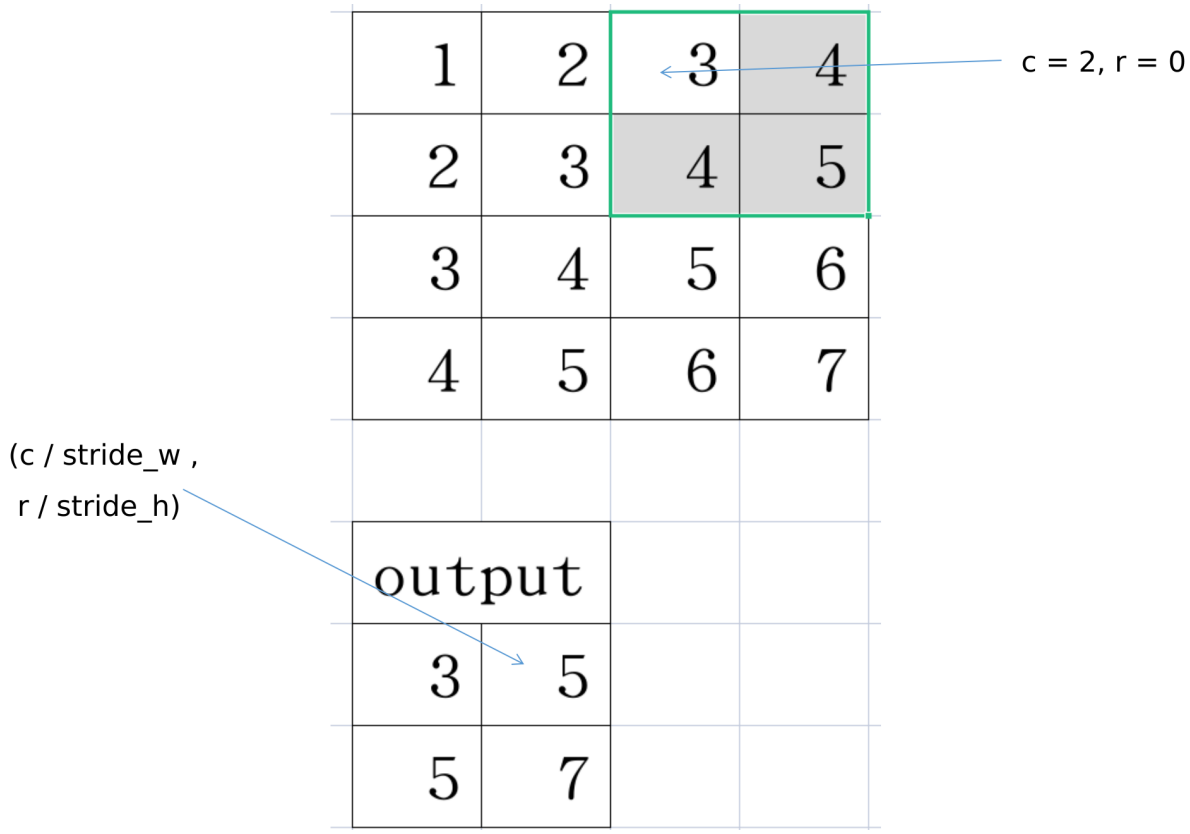

在以上情况中，**窗口的滑动步长为2，窗口此时所在的列c等于2，窗口所在的行r等于0**。通过观察下面的输出张量，我们可以看出，在该时刻要写入的输出值为5，其写入位置的计算方法如下：

1. 写入位置的列 $= c/stride\_w = 2/2 = 1$
2. 写入位置的行 $= r/stride\_h = 0/2 = 0$

所以对于该时刻，池化窗口求得的最大值为5，写入的位置为 $output(0, 1)$.

池化算子的注册

我们在`maxpooling.cpp`的最后，使用上节课中提到的算子注册类，将最大池化的初始化过程注册到了推理框架中。接下来我们来看一下最大池化算子的初始化过程**MaxPoolingLayer::GetInstance**.`

```
LayerRegistererWrapper
kMaxPoolingGetInstance("nn.MaxPool2d",

 MaxPoolingLayer::GetInstance);
```

池化算子的实例化函数

```
ParseParameterAttrStatus
MaxPoolingLayer::GetInstance(
    const std::shared_ptr<RuntimeOperator>& op,
    std::shared_ptr<Layer>& max_layer) {
  ...
  const std::map<std::string,
std::shared_ptr<RuntimeParameter>>& params =
      op->params;

```

传入参数之一是`RuntimeOperator`,回顾前两节课，这个数据结构中包含了算子初始化所需的参数和权重信息，我们首先访问并获取该算子中的所有参数`params`.

```
if (params.find("stride") == params.end()) {
    LOG(ERROR) << "Can not find the stride parameter";
    return ParseParameterAttrStatus::kParameterMissingStride;
  }

  auto stride =
 std::dynamic_pointer_cast<RuntimeParameterIntArray>(params.at("stride"));
  if (!stride) {
    LOG(ERROR) << "Can not find the stride parameter";
    return ParseParameterAttrStatus::kParameterMissingStride;
  }
  ...
```

在以上的代码中，我们获取到了用于初始化池化算子的`stride`参数，即窗口滑动步长。如果参数中没有`stride`参数，则返回对应的错误代码。

```
  if (params.find("padding") == params.end()) {
    LOG(ERROR) << "Can not find the padding parameter";
    return ParseParameterAttrStatus::kParameterMissingPadding;
  }

  auto padding = std::dynamic_pointer_cast<RuntimeParameterIntArray>(params.at("padding"));
  if (!padding) {
    LOG(ERROR) << "Can not find the padding parameter";
    return ParseParameterAttrStatus::kParameterMissingPadding;
  }
```

对于获得算子其他的初始化（如以上的填充大小`padding`）参数同理，我们可以先判断`params`键值对中是否存在名为`padding`的键。如果存在，则进行访问。

```
  auto kernel_size = std::dynamic_pointer_cast<RuntimeParameterIntArray>(
      params.at("kernel_size"));
  if (!kernel_size) {
    LOG(ERROR) << "Can not find the kernel size parameter";
    return ParseParameterAttrStatus::kParameterMissingKernel;
  }
  const auto& padding_values = padding->value;
  const auto& stride_values = stride->value;
  const auto& kernel_values = kernel_size->value;
```

在以上代码中，首先我们尝试获取`params`中的`kernel size`参数。如果该参数存在，则进行访问；如果不存在，则返回相应的错误码。随后，我们可以分别获取填充大小、步长大小和滑动窗口大小的参数值。

```
 max_layer = std::make_shared<MaxPoolingLayer>(
      padding_values.at(0), padding_values.at(1),
kernel_values.at(0),
      kernel_values.at(1), stride_values.at(0),
stride_values.at(1));
```

最后，我们可以使用这些参数对池化算子进行初始化，并将其赋值给`max_layer`参数进行返回。

池化算子的单元测试

第1个单元测试的目的是测试该算子（池化算子）是否已经被成功注册到算子列表中。如果已经注册成功，则通过测试。

```
TEST(test_registry, create_layer_poolingforward) {
  std::shared_ptr<RuntimeOperator> op =
std::make_shared<RuntimeOperator>();
  op->type = "nn.MaxPool2d";
  std::vector<int> strides{2, 2};
  std::shared_ptr<RuntimeParameter> stride_param =
std::make_shared<RuntimeParameterIntArray>(strides);
  op->params.insert({"stride", stride_param});

  std::vector<int> kernel{2, 2};
  std::shared_ptr<RuntimeParameter> kernel_param =
std::make_shared<RuntimeParameterIntArray>(strides);
  op->params.insert({"kernel_size", kernel_param});

  std::vector<int> paddings{0, 0};
  std::shared_ptr<RuntimeParameter> padding_param =
std::make_shared<RuntimeParameterIntArray>
(paddings);
  op->params.insert({"padding", padding_param});
```

```
15
16    std::shared_ptr<Layer> layer;
17    layer = LayerRegisterer::CreateLayer(op);
18    ASSERT_NE(layer, nullptr);
19  }
```

在以上的代码中，我们将`RuntimeOperator`的类型设置为池化，将池化大小参数设置为`3 x 3`，将填充大小设置为0，并将滑动窗口的步长设置为2。

设置完毕后，我们将使用`CreateLayer`函数传递该参数，并返回相应的池化算子。这一步骤已在上节课中进行了详细的讲解。

在下面的单元测试中，我们同样将池化窗口的大小设置为2，并且将滑动窗口的步长设置为2。同时，关于池化算子的输入值，我们做如下图的设置：

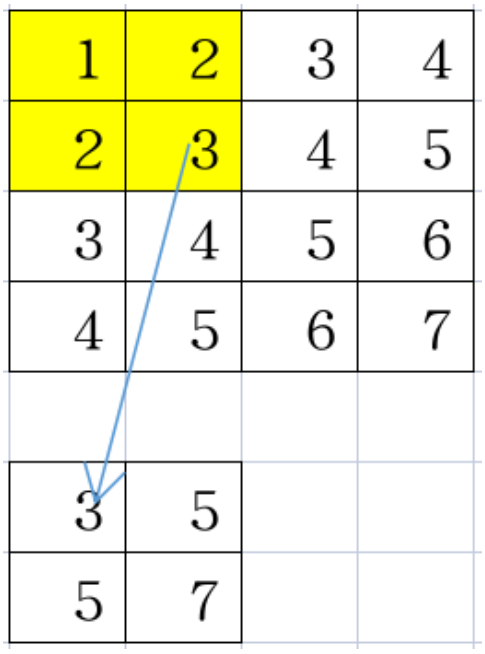


```
1  TEST(test_registry, create_layer_poolingforward_1) {
2    ...
3    ...
4    std::shared_ptr<Layer> layer;
5    layer = LayerRegisterer::CreateLayer(op);
6    ASSERT_NE(layer, nullptr);
7
```

```
  sftensor tensor = std::make_shared<ftensor>(1, 4, 4);
  arma::fmat input = arma::fmat("1,2,3,4;"
                                "2,3,4,5;"
                                "3,4,5,6;"
                                "4,5,6,7");
  tensor->data().slice(0) = input;
  std::vector<sftensor> inputs(1);
  inputs.at(0) = tensor;
  std::vector<sftensor> outputs(1);
  layer->Forward(inputs, outputs);

  ASSERT_EQ(outputs.size(), 1);
  outputs.front()->Show();
}
```

我们在`layer->Forward(inputs, outputs)`中使用初始化完毕的池化算子，对特定的输入值进行推理，池化算子的预测结果如下所示，可以看出符合我们之前的逻辑推导过程。

```
I20230721 14:05:09.855405  3224 tensor.cpp:201]
   3.0000   5.0000
   5.0000   7.0000
```

卷积算子的定义

卷积是信号处理和图像处理中常用的运算操作之一。它通过将输入信号（如图像、音频等）与一个卷积核（也称为滤波器或权重）进行相乘和累加的过程，用于在深度神经网络中提取特定的特征。因此，可以说卷积是最常用的算子之一。

- 在离散情况下，一维卷积操作可以定义为：

$$y[n] = \sum_{k=-\infty}^{\infty} x[k] \cdot h[n-k]$$

其中，x表示输入信号，h表示卷积核，y表示输出信号。这个公式表示输出信号中的每个元素 $y[n]$是通过对输入信号 x进行加权累加计算得到的，计算过程中使用了卷积核 h确定的权重。

- 更多的场景中我们一般面对的是二维输入（多通道，此处以单通道为例），这时候我们只需要将卷积定义拓展为二维：

  $$Y[i,j] = \sum_m \sum_n H[m,n] \cdot X[i+m, j+n]$$

其中，X表示输入矩阵，H表示卷积核，Y表示输出矩阵，i和j表示输出矩阵中的输出像素坐标，m和n表示卷积核中的坐标，$i+m$和$j+n$用于将卷积核和输入矩阵进行对齐，分别表示输入图像中的某个元素坐标。**通过这两个偏移量，我们可以确定卷积核在输入矩阵中的位置，并将其与对应位置的像素值相乘，然后求和得到输出矩阵的每个元素**$Y[i,j]$。

直观展示

- 为了直观解释，我们对二维卷积的计算过程进行直观展示，如下图，卷积核以滑动窗口的形式，从输入中划过，计算点积并求和，得到卷积后的输出存于`output`中。

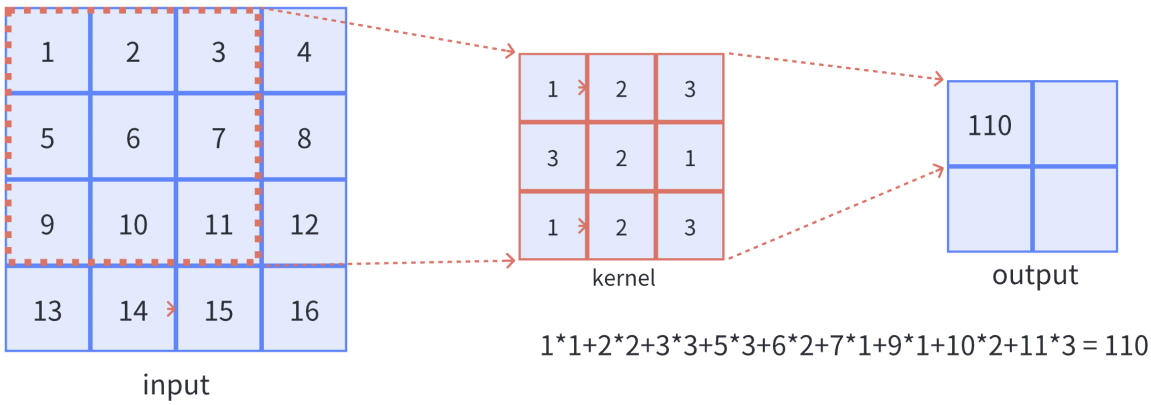

- 单通道可以直观地被拓展成多通道，只需对多个单通道的卷积结果求和即可（请注意，下图中的kernel属于同一个卷积核中的不同通道），此时需要注意的是输入的通道数与卷积核的通道数需要保持一致。

  如下图所示，可以看到一个多通道的输入和一个多通道的卷积核进行卷积计算，最后得到了**一个单通道的输出**`output`.

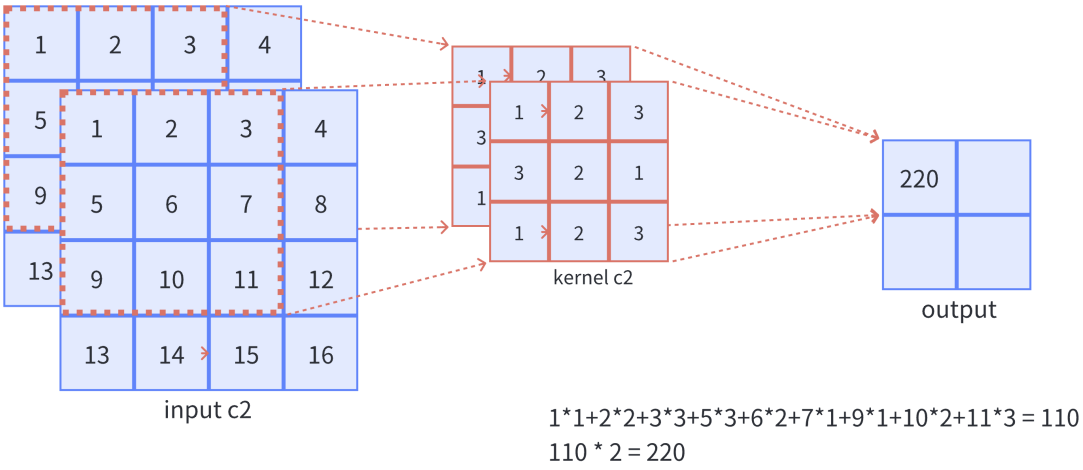

- 对于单通道输出，我们只需要一个卷积核就可以完成，**如果想要使得输出为多通道，则需使用多个不同的卷积核，即卷积核个数对应输出通道个数**。

  如下图所示，可以看到，如果使用两个卷积核，最后会产生一个**多通道的输出**`output`，它有两个通道，分别为`c1`和`c2`.

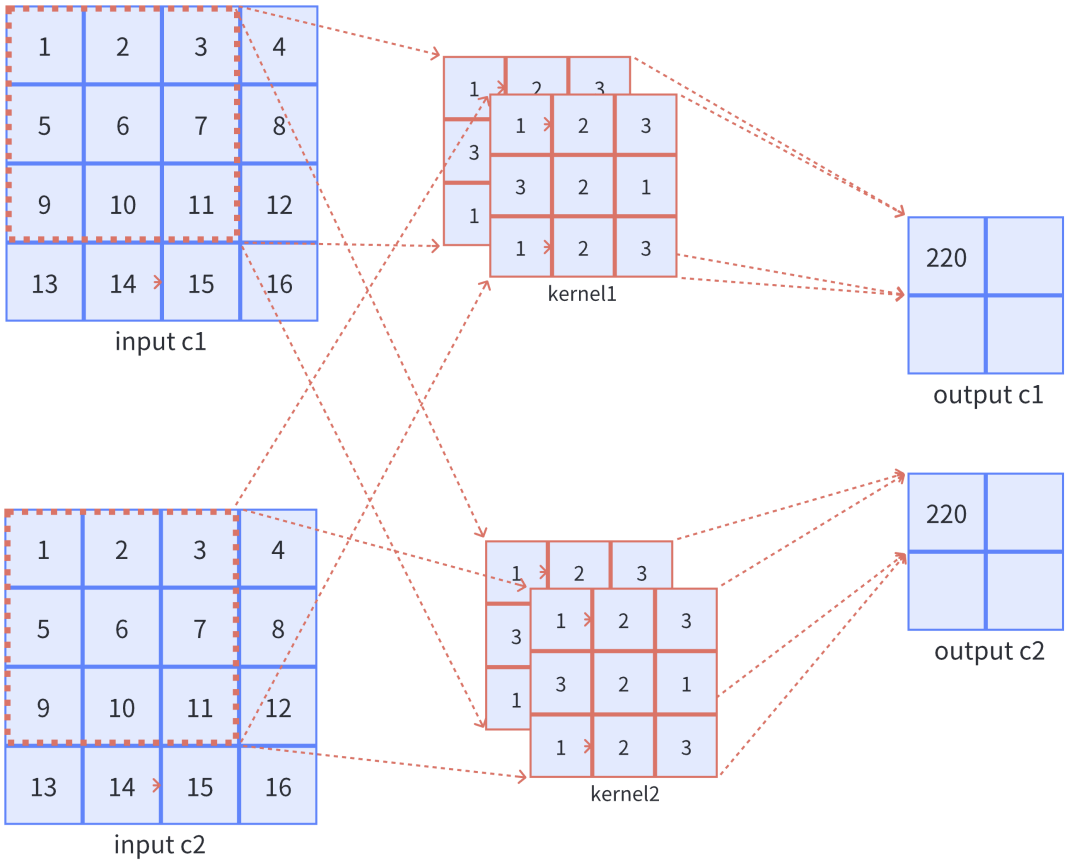

- 组卷积（`group conv`），顾名思义就是将卷积分组，即在深度上进行分组，假设group=2，则表示我们将原有的输入数据分成2组，如上图图所示，原本一个卷积核管全部通道，当分组之后，一个卷积核只需要管 $\frac{input\ channel}{group} = 2/2 = 1$个通道，即如下图所示。
- 分组卷积早在`AlexNet`便得到了应用，Alex认为组卷积能够增加 卷积核之间的对角相关性，并减少训练参数，不容易过拟合，达到类似正则的效果。从下图可以看出，如果对一个多通道的输入运用组卷积，最后得到了一个多通道的输出`output`，它有两个通道，分别为`c1`和`c2`.

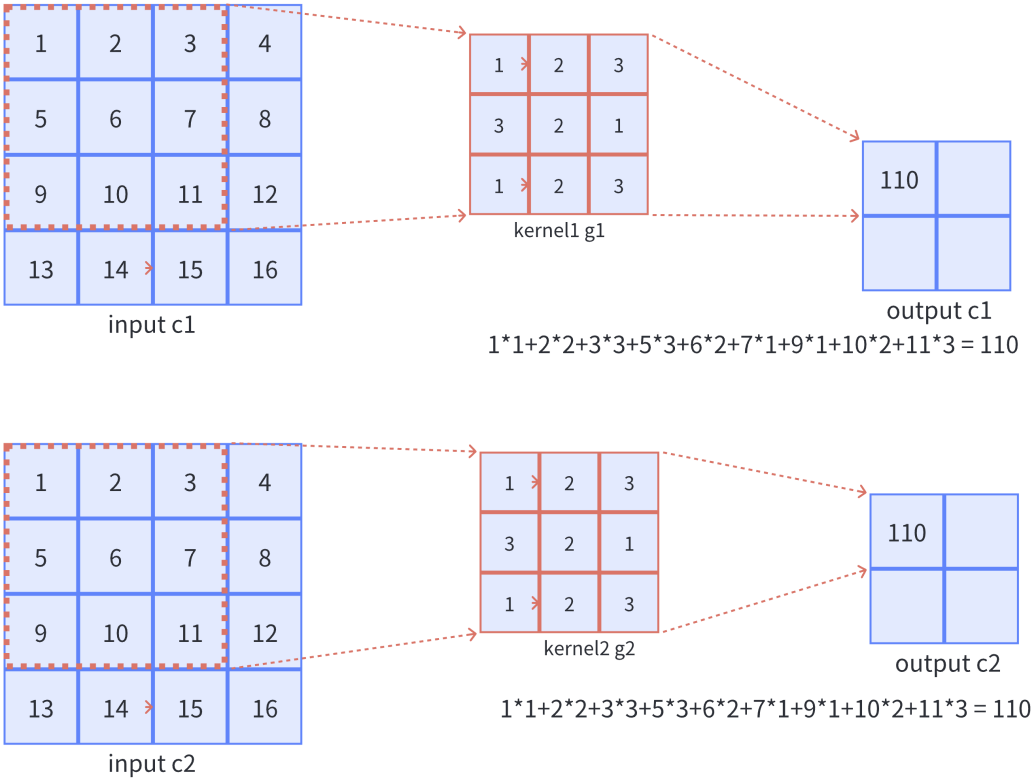

在本节中，我们描述了一维和二维卷积的基本定义，并通过直观地解释了二维卷积的运行过程。**在这个过程中，我们发现卷积核的通道数需要与输入数据的通道数保持一致，而卷积核的数量则代表了输出数据的通道数**。在卷积计算中，输入输出大小的维度有以下的对应关系：

$$output\ size = floor(\frac{input\ size + padding - kernel\ size}{stride} + 1)$$

Im2col优化卷积计算

- `Im2col`的核心思想是将卷积计算转化成矩阵计算，利用现有较为成熟的矩阵加速方法实现卷积运算的加速
- 我们仍然**从最简单的单通道开始**：
  - 下图向我们展示单通道卷积的`Im2col`展开方式：对于输入，每行代表一个卷积核窗口扫过的区域，展开的行数为`input-col`，也就是卷积总执行次数，每行的列数为一个卷积核元素和，本例中卷积核被展开为一个4×9的矩阵；

- 对于卷积核，一个卷积核展成一列，本例中卷积核被展开为一个9×1的向量；
- 如此，卷积就被成功转化成矩阵计算，我们来看下面的图示。

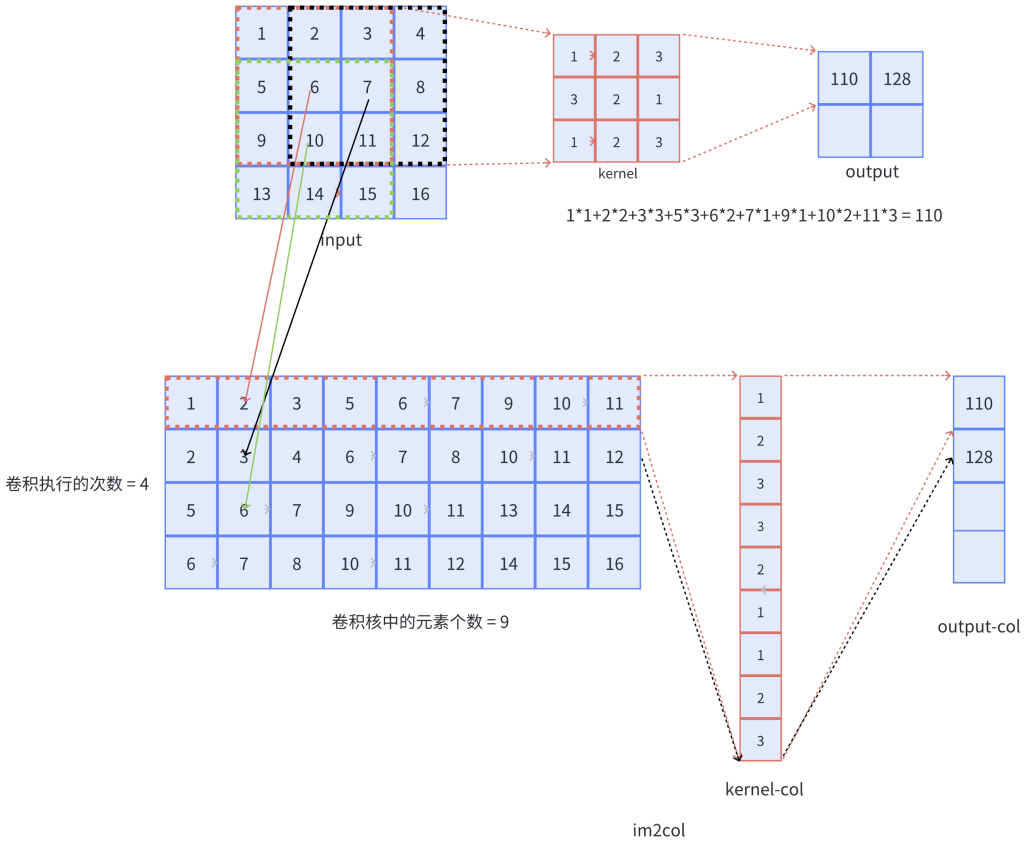

- 如果是对**多通道的输入**进行卷积计算呢?

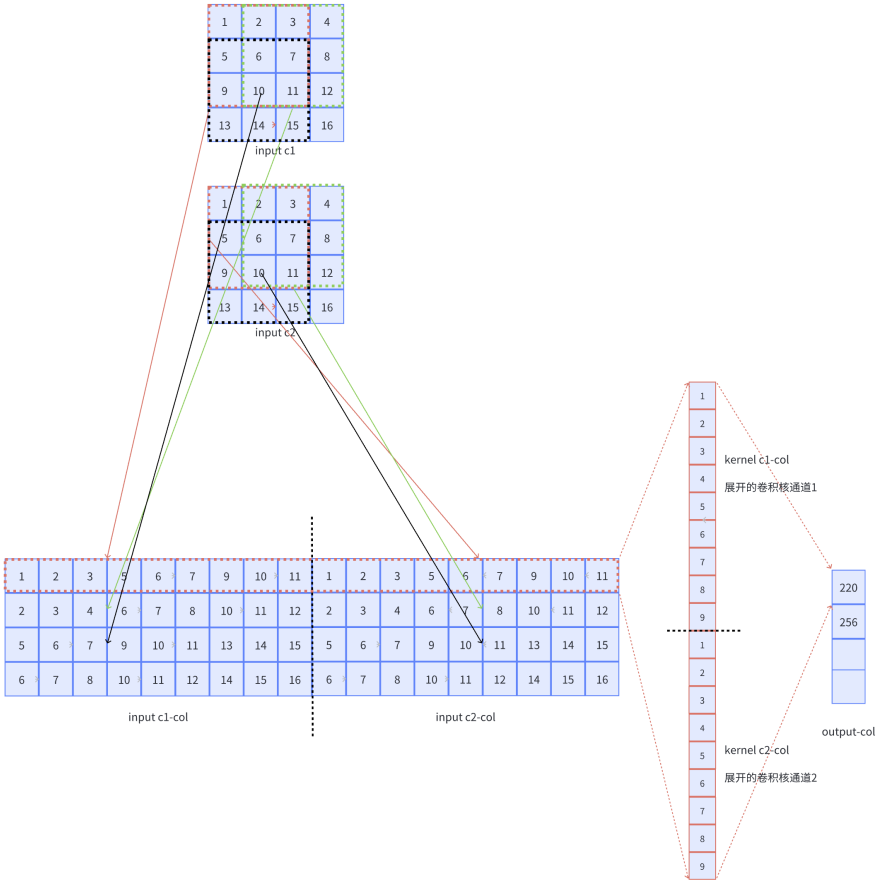

- 同理，**对于多通道输出**(有多个卷积核的情况)，则有：

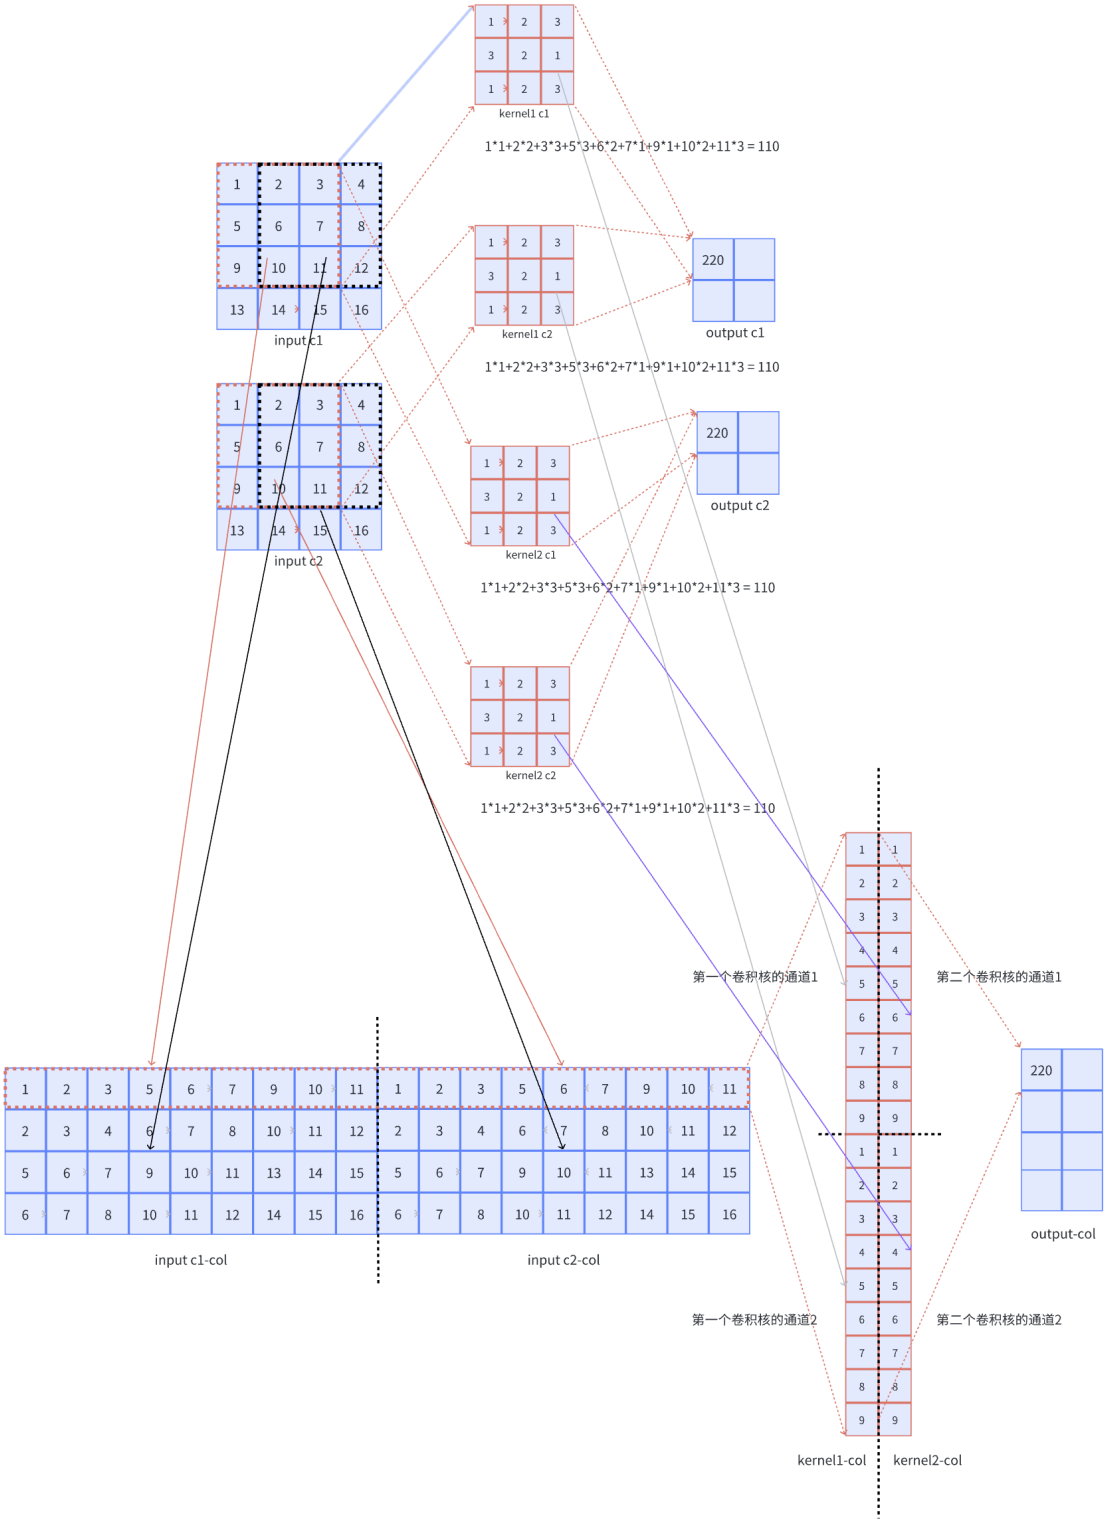

KuiperInfer中的分组卷积

我们假设`group`的数量为2, 如果输入特征图和卷积核的通道数为4, 共有4个卷积核.

当`group`等于2时，我们将输入特征图的4个通道分为2组，同时将4个卷积核也分为2组，每组分配到两个卷积核，每个卷积核的通道数为2。

1. `group`等于2, 我们将输入特征图的4个通道一分为2.

2. 将4个卷积核一分为2, 分成两组, **每组分配到两个卷积核，每个卷积核的通道数为2**, 它们分别是`group1`和`group2`.

   `group1`处理第1份通道数为2的输入特征图, `group2`处理第2份通道数为2的输入特征图

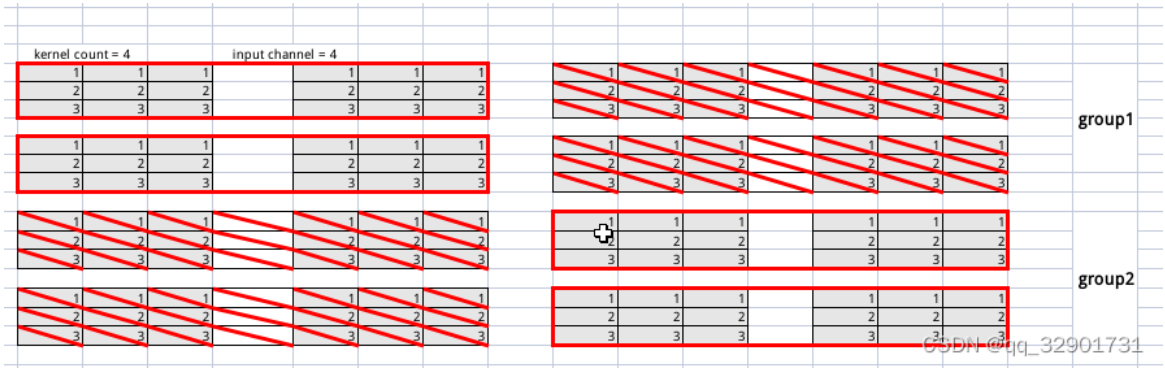

   对于两组卷积，第一组卷积处理`channel = 0, 1`，第二组卷积处理`channel = 2,3`.

3. 做分组卷积，属于`group1`的两个卷积核与属于`group1`的输入特征图通道展开后进行相乘，属于`group2`的两个卷积核与属于`group2`的输入特征图通道展开后进行相乘。

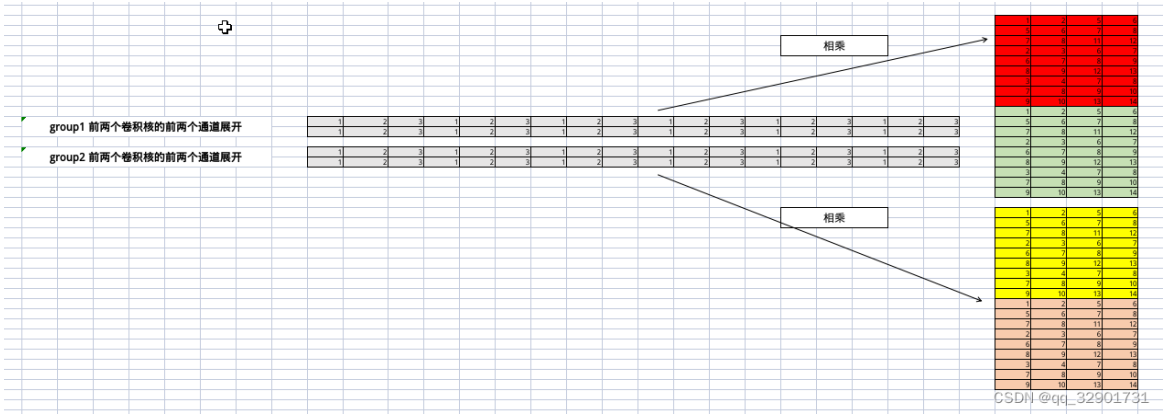

KuiperInfer中的Im2Col实现

> 因为`armadillo`自身是列主序的，所以我们这里相当于在做`Im2Row`，但是这个不影响我们的课程内容，大家记住这个奇怪的设定就好。

`Im2Col`的代码位于`convolution.cpp`中。

```
arma::fmat ConvolutionLayer::Im2Col(sftensor input, uint32_t kernel_w,
                                    uint32_t kernel_h, uint32_t input_w,
                                    uint32_t input_h, uint32_t input_c_group,
                                    uint32_t group, uint32_t row_len,
                                    uint32_t col_len) const {
  arma::fmat input_matrix(input_c_group * row_len, col_len);
  const uint32_t input_padded_h = input_h + 2 * padding_h_;
  const uint32_t input_padded_w = input_w + 2 * padding_w_;
  const float padding_value = 0.f;
```

我们首先来看一下传入到这个函数中的参数，依次是：

1. `input`：输入特征图像
2. `kernel_*`：卷积核的大小
3. `input_*`：输入特征图像的尺寸大小，也就是`input`的尺寸大小
4. `input_c_group`：每个`group`处理的通道数量，**如前文所叙，我们会将输入特征图的通道按照组数进行切分**
5. `group`：当前进行`Im2Col`的组数(group)
6. `row_len`：$kernel\_w \times kernel\_h$，也就是上一节中卷积核展开后的列数或输入展开后的行数
7. `col_len`：卷积计算的次数，也就是卷积窗口滑动的次数

   对于下图的情况，`row_len`等于9，表示展开后的行数；`col_len`等于4，表示卷积窗口滑动的次数。

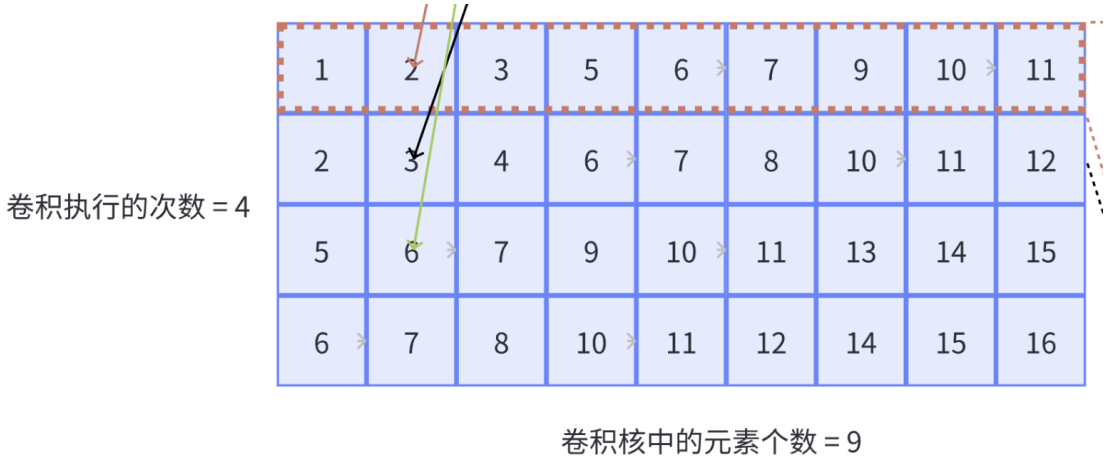


```
1   arma::fmat input_matrix(input_c_group * row_len,
col_len);
2   const uint32_t input_padded_h = input_h + 2 *
padding_h_;
3   const uint32_t input_padded_w = input_w + 2 *
padding_w_;
```

`input_matrix`用于存储对输入图像展开后的矩阵，`input_padded_*`表示输入填充后的尺寸大小。为什么这里的`input_matrix`行数等于$input_c_group \times row_len$呢，我们从下方的图中可以看出，对于多输入通道的情况，它的列数等于输入通道数和卷积核相乘（**因为我们是**

列主序的，实际执行`Im2Row`，所以行列相反），它的行数等于`col_len`（行列相反），也就是卷积窗口进行滑动的次数。

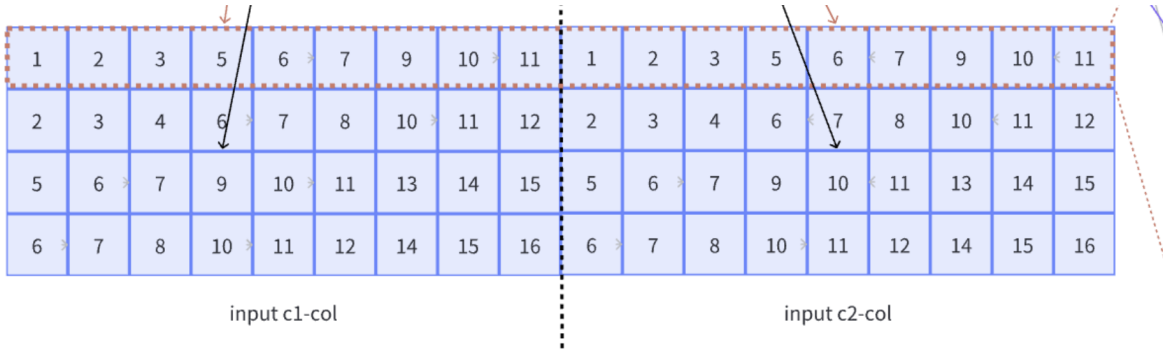


```
 for (uint32_t ic = 0; ic < input_c_group; ++ic) {
    float* input_channel_ptr =
        input->matrix_raw_ptr(ic + group * input_c_group);
    uint32_t current_col = 0;
    uint32_t channel_row = ic * row_len;
    for (uint32_t w = 0; w < input_padded_w - kernel_w + 1; w += stride_w_) {
      for (uint32_t r = 0; r < input_padded_h - kernel_h + 1; r += stride_h_) {
        float* input_matrix_ptr =
            input_matrix.colptr(current_col) + channel_row;
```

我们需要提取当前的输入通道，并将该通道的起始指针赋值给`input_channel_ptr`。其中，`channel_row`表示我们当前展开通道后开始摆放的起始位置，以第2个通道($ic = 2$)为例：

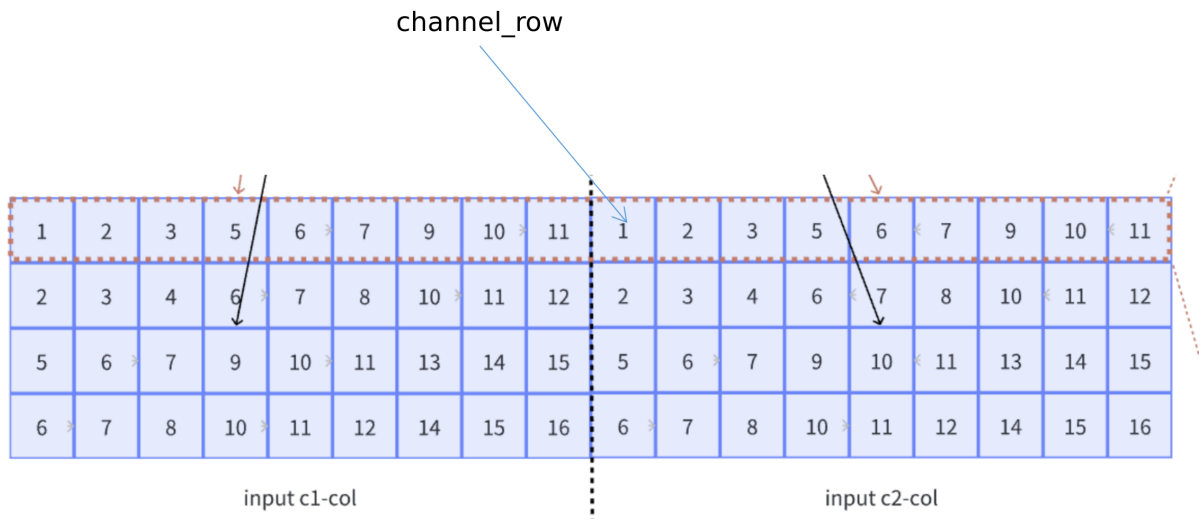

在第6 - 7行中，我们对一个输入通道进行窗口滑动，
`input_matrix_ptr`表示当前元素展开后存放的位置。

```
1  for (uint32_t kw = 0; kw < kernel_w; ++kw) {
2      const uint32_t region_w = input_h * (w + kw - padding_w_);
3      for (uint32_t kh = 0; kh < kernel_h; ++kh) {
4          if ((kh + r >= padding_h_ && kw + w >= padding_w_) &&
5              (kh + r < input_h + padding_h_ &&
6               kw + w < input_w + padding_w_)) {
7              float* region_ptr =
8                  input_channel_ptr + region_w + (r + kh - padding_h_);
9              *input_matrix_ptr = *region_ptr;
10         }
11         ...
12         input_matrix_ptr += 1;
```

`input_matrix_ptr`依次指向上图中`channel_row`之后的各个位置，**用于存放展开后的各元素**。

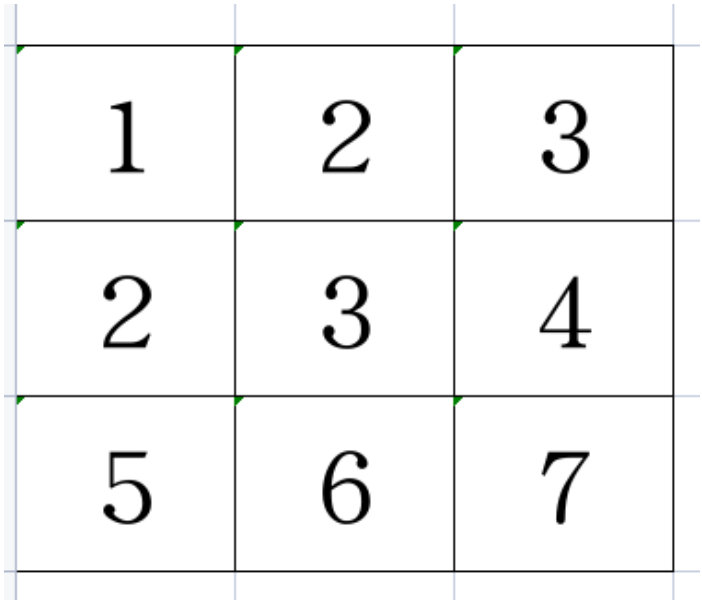

接下来，我们需要处理卷积窗口内的所有元素。首先，**我们要定位到当前需要展开的元素**`region_ptr`，也就是黄色范围。

定位的方法是先将指针定位到输入通道的列，即 $input\_channel\_ptr + (w + kw - padding\_w)$，然后再将指针定位到输入通道数的行，即 $input\_channel\_ptr + (r + kh - padding\_h)$。这样，我们就能得到当前需要处理元素的内存地址。

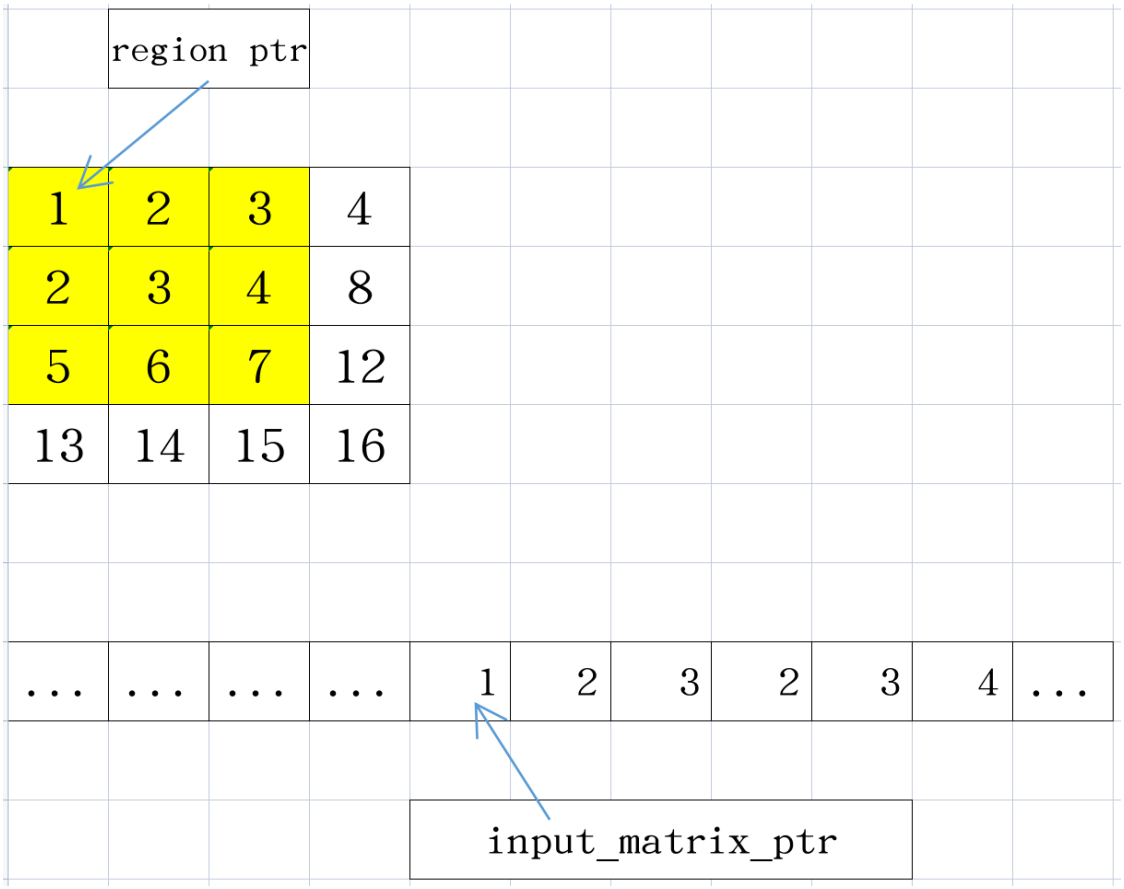

`region_ptr`表示正在展开的输入特征图的内存索引位置，而`input_matrix_ptr`表示展开后存放位置的指针。

卷积算子实现的主流程

```
InferStatus ConvolutionLayer::Forward(
    const
std::vector<std::shared_ptr<Tensor<float>>>& inputs,
    std::vector<std::shared_ptr<Tensor<float>>>&
outputs)
```

我们来看卷积算子中的主要实现流程，首先是对批次数据逐个处理。

```
 for (uint32_t i = 0; i < batch_size; ++i) {
   ...
   ...
 }
```

```
    const uint32_t input_c = input->channels();
    const uint32_t input_padded_h = input->rows() + 2 * padding_h_;
    const uint32_t input_padded_w = input->cols() + 2 * padding_w_;

    const uint32_t output_h =
        std::floor((int(input_padded_h) - int(kernel_h)) / stride_h_ + 1);
    const uint32_t output_w =
        std::floor((int(input_padded_w) - int(kernel_w)) / stride_w_ + 1);

   ...
    uint32_t col_len = output_h * output_w;
```

在以上的代码中，我们计算了输入张量的尺寸，输出张量的尺寸以及`col_len`（也就是卷积窗口执行计算的次数）。

```
uint32_t input_c_group = input_c / groups_;

for (uint32_t g = 0; g < groups_; ++g) {
    const auto& input_matrix =
        Im2Col(input, kernel_w, kernel_h, input->cols(), input->rows(),
               input_c_group, g, row_len, col_len);
    std::shared_ptr<Tensor<float>> output_tensor = outputs.at(i);
    if (output_tensor == nullptr || output_tensor->empty()) {
        output_tensor =
            std::make_shared<Tensor<float>>(kernel_count, output_h, output_w);
        outputs.at(i) = output_tensor;
    }
```

在以上的代码中，我们对`group`进行迭代遍历，其中g表示当前的组号，**`input_c_group`表示每组卷积需要处理的通道数，`Im2Col`函数中会对属于该组的输入通道进行展开**。

```
for (uint32_t g = 0; g < groups_; ++g) {
    ...
    ...
    const uint32_t kernel_count_group_start = kernel_count_group * g;
    for (uint32_t k = 0; k < kernel_count_group; ++k) {
        arma::frowvec kernel;
        if (groups_ == 1) {
            kernel = kernel_matrix_arr_.at(k);
        } else {
            kernel = kernel_matrix_arr_.at(kernel_count_group_start + k);
        }
        ConvGemmBias(input_matrix, output_tensor, g, k, kernel_count_group,
```

```
13                          kernel, output_w, output_h);
14      }
15  }
```

`kernel_count_group`是分组卷积中，**每组卷积分得的卷积核个数**，所以在第3行的for循环中，**我们使用`kernel_count_goup`，`k`等变量定位到对应的卷积核**。

$$kernel\ index = k + g \times kernel\ count\ group$$

这里我们对属于同一组的输入通道和卷积核（每组卷积核的个数是`kernel_count_group`个）进行逐一的相乘，也就是说，这里进行相乘的卷积核和输入通道都属于同一个`group`.

小结：

1. 我们先计算得到了每个组需要处理的通道数`input_channel_group`，随后**再对该组这些输入通道进行展开**（`Im2Col`函数中）。
2. 获取到1中对应的卷积核组，将它们逐个取出，取出的方式为：

   $$kernel\ index + group \times kernel\ count\ group$$

3. 然后，我们将**取出的同组每个卷积核**与**步骤1中得到的同一组输入通道**进行相乘，得到结果。

KuiperInfer中的GEMM实现

```
1  void ConvolutionLayer::ConvGemmBias(
2      const arma::fmat& input_matrix, sftensor
   output_tensor, uint32_t group,
3      uint32_t kernel_index, uint32_t
   kernel_count_group,
4      const arma::frowvec& kernel, uint32_t output_w,
   uint32_t output_h) const {
5
```

我们首先来看一下传入到这个函数中的参数，依次是：

1. `input_matrix`: 展开后的输入特征
2. `output_tensor`: 用于存放输出的矩阵
3. `group`: 当前进行`Im2Col`的组(group)数
4. `kernel*` :用于定位当前展开后的卷积核
5. `output_*`: 输出矩阵的尺度大小

```
  arma::fmat output(
      output_tensor->matrix_raw_ptr(kernel_index + group * kernel_count_group),
      output_h, output_w, false, true);
```

以上的代码中定位了输出矩阵所在的位置，`kernel_count_group`表示属于一个`group`的卷积核数量。

如前文所叙。`kernel_index`表示当前`group`内的卷积核索引，`group`表示当前的组数，所以我们使用$kernel\,index + group \times kernel\,count\,group$索引到当前卷积核对应的输出矩阵位置。

```
 if (!this->bias_.empty() && this->use_bias_) {
    std::shared_ptr<Tensor<float>> bias;
    bias = this->bias_.at(kernel_index);
    if (bias != nullptr && !bias->empty()) {
      float bias_value = bias->index(0);
      output = kernel * input_matrix + bias_value;
    } else {
      LOG(FATAL) << "Bias tensor is empty or nullptr";
    }
  } else {
    output = kernel * input_matrix;
  }
```

接下来，我们将展开后的输入矩阵`input_matrix`和展开后的卷积核`kernel`相乘，得到结果矩阵`output`。

卷积算子的实例化

我们在`convolution.cpp`的最后将该算子的实例化过程注册到了深度学习推理框架中。

```
LayerRegistererWrapper kConvGetInstance("nn.Conv2d",

 ConvolutionLayer::GetInstance);
```

具体的实例化函数如下，同样是先得到初始化算子需要的参数`params`：

```
ParseParameterAttrStatus
ConvolutionLayer::GetInstance(
    const std::shared_ptr<RuntimeOperator>& op,
    std::shared_ptr<Layer>& conv_layer) {
  CHECK(op != nullptr) << "Convolution operator is
nullptr";
  const std::map<std::string,
std::shared_ptr<RuntimeParameter>>& params =
      op->params;

```

这些参数的初始化过程，我们就不做详细的描述了，因为它和池化算子的初始化过程大同小异。

```
  conv_layer = std::make_shared<ConvolutionLayer>(
      out_channel->value, in_channel->value,
kernels.at(0), kernels.at(1),
      paddings.at(0), paddings.at(1), strides.at(0),
strides.at(1),
      groups->value, use_bias->value);
```

这里我们根据以上的得到的参数对卷积算子进行了初始化，**但是在这里，我们还没有对卷积算子中的权重(`weight`和`bias`)进行加载。**

我们重点来看一下卷积算子中的权重和偏移量初始化、加载过程：

```
1   const std::map<std::string,
std::shared_ptr<RuntimeAttribute>>& attrs =
2       op->attribute;
3     ...
4     const auto& bias = attrs.at("bias");
5     const std::vector<int>& bias_shape = bias-
>shape;
6     if (bias_shape.empty() || bias_shape.at(0) !=
out_channel->value) {
7       LOG(ERROR) << "The attribute of bias shape is
wrong";
8       return
ParseParameterAttrStatus::kAttrMissingBias;
9     }
10
11    const std::vector<float>& bias_values = bias-
>get<float>();
12    conv_layer->set_bias(bias_values);
13  }
```

在第1行中，我们获取到了`RuntimeOperator`中的权重变量`attrs`。然后我们尝试找到其中的`bias`键。如果该键存在，就获取其中的偏移量权重（`bias`），并将其赋值给`conv_layer`。

```
1   const auto& weight = attrs.at("weight");
2   const std::vector<int>& weight_shape = weight-
>shape;
3   if (weight_shape.empty()) {
4     LOG(ERROR) << "The attribute of weight shape is
wrong";
5     return
ParseParameterAttrStatus::kAttrMissingWeight;
6   }
7
8   const std::vector<float>& weight_values = weight-
>get<float>();
9   conv_layer->set_weights(weight_values);
```

```
10
11    auto conv_layer_derived =
12        std::dynamic_pointer_cast<ConvolutionLayer>
    (conv_layer);
13    CHECK(conv_layer_derived != nullptr);
14    conv_layer_derived->InitIm2ColWeight();
15    return
    ParseParameterAttrStatus::kParameterAttrParseSuccess
    ;
```

同样在以上的第一行中，我们尝试获取`RuntimeOperator`中的`weight`键，如果该键存在，就获取其对应的权重变量，并将它赋值给`conv_layer`. 至此，我们完成了卷积算子的实例化。对了，我们可以看到，这里有一句`InitIm2ColWeight`, 它是在展开该卷积算子对应的卷积核。

因为对于一个卷积算子来说，它的输入是不确定的，所以我们需要在运行时再调用`Im2Col`进行展开，而一个卷积算子中的权重是固定的，所以可以在初始化的时候进行展开。

卷积算子的单元测试

我们单元测试对应的卷积计算图示如下，是一个多输入通道(`input c1`和`input c2`)和多输出通道(`output`的`c1`和`c2`)的卷积算子。

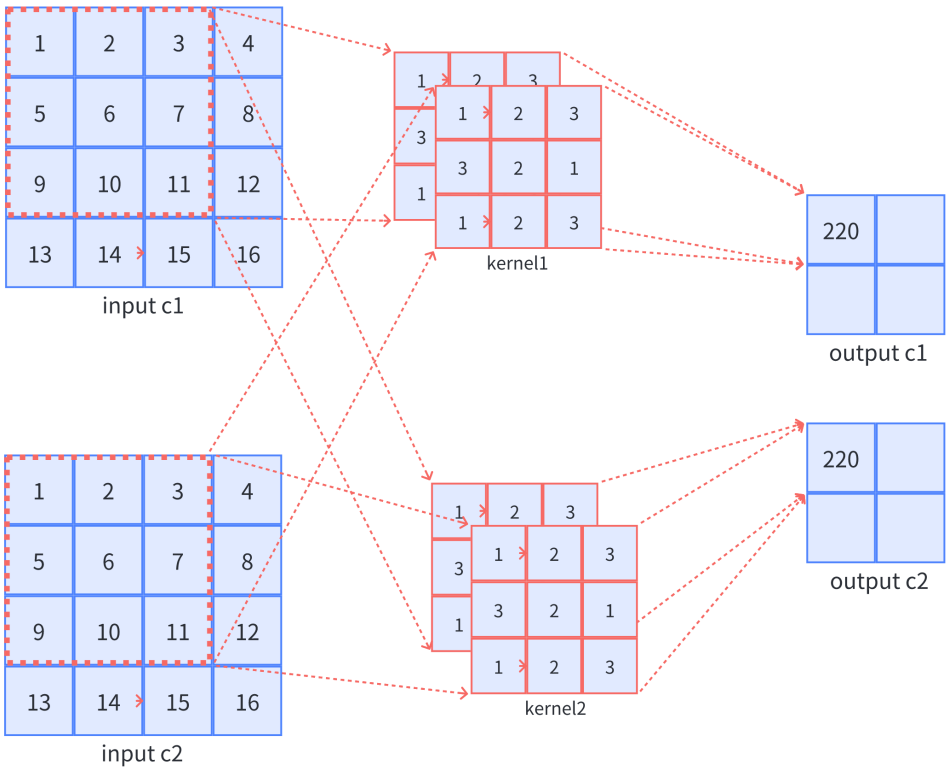


```
TEST(test_registry, create_layer_convforward) {
  const uint32_t batch_size = 1;
  std::vector<sftensor> inputs(batch_size);
  std::vector<sftensor> outputs(batch_size);

  const uint32_t in_channel = 2;
  for (uint32_t i = 0; i < batch_size; ++i) {
    sftensor input = std::make_shared<ftensor>
(in_channel, 4, 4);
    input->data().slice(0) = "1,2,3,4;"
                             "5,6,7,8;"
                             "9,10,11,12;"
                             "13,14,15,16;";

    input->data().slice(1) = "1,2,3,4;"
                             "5,6,7,8;"
                             "9,10,11,12;"
                             "13,14,15,16;";
    inputs.at(i) = input;
  }
```

```
  const uint32_t kernel_h = 3;
  const uint32_t kernel_w = 3;
  const uint32_t stride_h = 1;
  const uint32_t stride_w = 1;
  const uint32_t kernel_count = 2;
  std::vector<sftensor> weights;
  for (uint32_t i = 0; i < kernel_count; ++i) {
    sftensor kernel = std::make_shared<ftensor>(in_channel, kernel_h, kernel_w);
    kernel->data().slice(0) = arma::fmat("1,2,3;"
                                         "3,2,1;"
                                         "1,2,3;");
    kernel->data().slice(1) = arma::fmat("1,2,3;"
                                         "3,2,1;"
                                         "1,2,3;");
    weights.push_back(kernel);
  }
  ConvolutionLayer conv_layer(kernel_count, in_channel, kernel_h, kernel_w, 0,
                              0, stride_h, stride_w, 1, false);
  conv_layer.set_weights(weights);
  conv_layer.Forward(inputs, outputs);
  outputs.at(0)->Show();
}
```

课程作业

1. 仔细阅读这个课件并调试其中的代码，观察状态和变量的变换。因为本节课内容非常难，跟着看一遍不一定能全部掌握
2. 我们的单元测试只测试了group = 1的情况，针对分组卷积，即group != 1的情况，请自己构造单元测试，并逐步调试代码。